



UNIVERSIDAD
DE SEVILLA

· 1505 ·

Universidad de Sevilla

Facultad de Ingeniería / Escuela de Informática

Trabajo Fin de Máster (TFM)

**Proyectos Tecnológicos Mediante Metodología Ágil. Gestión de
Riesgos y Complejidad. Caso República Dominicana.**

Programa de Máster

Lógica, Computación e Inteligencia Artificial

Grupo Universitario

1040542

Sustentado por

Leandro Arnulfo Leonardo Santana

ID / Matrícula

JXS3388

Tutor

Juan Manuel Álvarez Espada

Sevilla, Reino de España

Fecha: 05 de junio 2025

Proyectos Tecnológicos Mediante Metodología Ágil. Gestión de Riesgos y Complejidad. Caso República Dominicana.

Copyright

© 2025 Leandro Arnulfo Leonardo Santana

Todos los derechos reservados.

Este documento es propiedad intelectual de Leandro Arnulfo Leonardo Santana y está protegido por las leyes de derechos de autor. No se permite la reproducción total o parcial de este trabajo, ni su incorporación a un sistema de recuperación de información, ni su transmisión en cualquier forma o por cualquier medio, ya sea electrónico, mecánico, por fotocopia, grabación u otros, sin el permiso previo y por escrito del autor.

Cualquier uso no autorizado de este material, incluyendo pero no limitado a, su reproducción, distribución, o cualquier otra forma de aprovechamiento, constituirá una violación de los derechos de autor y estará sujeto a las acciones legales correspondientes.

Contacto del autor:

Leandro Leonardo

LEANDROLEONARDOSAN@GMAIL.COM

Dedicatoria

Este trabajo está dedicado, con el más profundo agradecimiento, a mi familia, cuyo apoyo incondicional y constante ha sido mi fuente de fortaleza en cada etapa de este proceso. A mis padres, por su amor, paciencia y por enseñarme a nunca rendirme, y a mis hermanos, por su constante motivación y comprensión.

A mi vecina, Vicenta Poueriet, por su invaluable ayuda y sabiduría en momentos de incertidumbre. Su generosidad y disposición para orientarme cuando más lo necesitaba han sido fundamentales para la realización de este trabajo.

A mis amigos y roommates, quienes siempre han estado allí para ofrecerme su perspectiva y apoyo, haciendo que este camino fuera más llevadero. Su amistad ha sido un pilar importante en este proceso.

Y, finalmente, a todas las personas que, de una u otra manera, han influido positivamente en la consecución de este proyecto. A aquellos que, aunque no mencionados específicamente, han dejado su huella en cada etapa de este recorrido.

Agradecimientos

A los arquitectos del conocimiento, cuyas ideas han pavimentado el camino por el cual transitan los proyectos más innovadores de nuestra era. A los matemáticos y científicos de datos, guardianes de la verdad oculta en números, quienes, con precisión milimétrica, delinean las complejas estructuras que gobiernan nuestro mundo.

A mi tutor y supervisor, Juan Manuel Álvarez Espada, cuya orientación ha sido una brújula valiosa durante el desarrollo de este trabajo. Su enfoque en la gestión de riesgos y las redes bayesianas ha sido clave, y aunque su tiempo era limitado, su contribución ha sido importante para el avance de esta investigación.

A la Universidad de Sevilla, bastión de la educación y la investigación, por brindar un refugio seguro para el pensamiento crítico y la innovación. A pesar de los desafíos inherentes a toda gran institución, los recursos proporcionados han sido un pilar esencial, permitiendo que las ideas se conviertan en resultados tangibles y que las hipótesis sean puestas a prueba bajo la luz de la ciencia y la razón.

A los maestros de la informática y la teoría de la complejidad, quienes, como cartógrafos del ciberespacio, han delineado los mapas que permiten a la tecnología moderna entender y modelar el caos del mundo real. Sus

enseñanzas han sido no solo instructivas, sino también inspiradoras, ofreciendo las herramientas necesarias para desentrañar los misterios de los sistemas complejos.

A mi vecina Vicenta Pueriet, a quien deseo expresar un agradecimiento especial por su invaluable ayuda en momentos de incertidumbre. Su asesoría me brindó el rumbo que necesitaba cuando no sabía qué camino tomar, y por ello estaré siempre agradecido.

A la Ministerio de Educación Superior, Ciencia y Tecnología (MESyCT), por su apoyo constante y por facilitar los recursos necesarios para que este proyecto pudiera llevarse a cabo, así como por la beca ofrecida que me permitió dedicarme de manera plena a esta investigación.

Y a mi familia, amigos y roommates, quienes han sido los vigías constantes en esta travesía, su paciencia y apoyo incondicional han proporcionado el ancla que mantiene el barco firme frente a las tempestades. Sus palabras de aliento y su fe inquebrantable han sido un recordatorio constante de que incluso los desafíos más arduos pueden ser superados con determinación y coraje.

Este trabajo está dedicado a todos aquellos que buscan entender los intrincados engranajes de nuestro universo digital, que con cada línea de código y cada fórmula matemática, se esfuerzan por construir un futuro más transparente, equitativo y conectado. A ustedes, mis más profundos agradecimientos.

Autorización de Publicación Electrónica

Santo Domingo, Distrito Nacional, 05/06/2025

Por este medio autorizo la publicación electrónica de la versión aprobada de mi Proyecto Final de Máster (TFM) bajo el título Proyectos Tecnológicos Mediante Metodología Ágil. Gestión de Riesgos y Complejidad. Caso República Dominicana. **en el campus virtual y en otros espacios de divulgación electrónica de esta Institución.**

En la siguiente página encontrarán la estructura o formato de los datos para la descripción del trabajo.

Atentamente,

Leandro Arnulfo Leonardo Santana

Datos para la descripción del trabajo:

Título	Proyectos Tecnológicos Mediante Metodología Ágil. Gestión de Riesgos y Complejidad. Caso República Dominicana.
Autor	Leandro Arnulfo Leonardo Santana
Resumen	Este estudio evalúa un modelo híbrido que combina Redes Bayesianas (BN) y aprendizaje automático (Naïve Bayes y Random Forest) para gestionar riesgos y complejidad en proyectos ágiles del sector público dominicano. Se identifican variables clave mediante una revisión sistemática y se presentan recomendaciones prácticas como la creación de un repositorio nacional y capacitación en análisis probabilístico.
Programa	Máster en Lógica, Computación e Inteligencia Artificial
Palabras clave	Gestión de riesgos, Metodologías ágiles, Entornos VUCA, Redes Bayesianas, República Dominicana
Contacto	leandroleonardosan@gmail.com

Acrónimos, Abreviaturas y Siglas

Acrónimo	Descripción en Inglés	Descripción en Español
API	Application Programming Interface	Interfaz de Programación de Aplicaciones
BIC	Bayesian Information Criterion	Criterio de Información Bayesiano
BN	Bayesian Networks	Redes Bayesianas
CI/CD	Continuous Integration / Continuous Delivery	Integración Continua y Entrega Continua
Colab	Google Colaboratory	Google Colaboratory (entorno para ejecutar código Python en la nube)

CPD	Conditional Probability Distribution	Tabla de Probabilidad Condicional
DBN	Dynamic Bayesian Networks	Redes Bayesianas Dinámicas
INAP	National Institute of Public Administration	Instituto Nacional de Administración Pública
LeSS	Large Scale Scrum	Scrum a Gran Escala
MCC	Matthews Correlation Coefficient	Coeficiente de Correlación de Matthews
MESCyT	Ministry of Higher Education, Science and Technology	Ministerio de Educación Superior, Ciencia y Tecnología
ML	Machine Learning	Aprendizaje Automático

OGTIC	Government Office of Information and Communication Technologies	Oficina Gubernamental de Tecnologías de la Información y Comunicación
PMO	Project Management Office	Oficina de Gestión de Proyectos
PyCharm	Integrated Development Environment for Python	Entorno de desarrollo integrado (IDE) para Python
RF	Random Forest	Bosque Aleatorio
ROC	Receiver Operating Characteristic	Característica Operativa del Receptor
SAFe	Scaled Agile Framework	Marco Escalado Ágil
SMOTE	Synthetic Minority Over-sampling Technique	Técnica Sintética de Sobremuestreo de Minorías

VUCA	Volatility, Uncertainty, Complexity, Ambiguity	Volatilidad, Incertidumbre, Complejidad y Ambigüedad
XP	Extreme Programming	Programación Extrema

Índice de contenido

Copyright.....	2
Dedicatoria.....	3
Agradecimientos.....	4
Autorización de Publicación Electrónica.....	6
Acrónimos, Abreviaturas y Siglas.....	8
Resumen.....	17
Abstract.....	18
Introducción.....	19
Capítulo 1: Planteamiento del Problema.....	23
Capítulo 2: Marco Teórico.....	34
2.1 Entornos VUCA.....	34
2.2 Proyectos tecnológicos en entornos VUCA (RD).....	37
2.3 Metodologías ágiles y tradicional: comparación local.....	38
2.4 Riesgos, complejidad y triángulo de hierro.....	41

2.5 Fundamentos de Redes Bayesianas (BN).....	44
2.6 Aprendizaje automático supervisado.....	49
2.6.1 Naïve Bayes.....	50
2.6.2 Random Forest.....	53
2.6.3 Sinergias BN + ML.....	55
2.7 Revisión crítica de la literatura y construcción del marco conceptual.....	57
2.8 Datos sintéticos: generación, balanceo y limitaciones.....	59
2.8.1 Generación de datos sintéticos.....	59
2.8.2 Balanceo de clases.....	60
2.8.3 Limitaciones.....	61
Estado del Arte.....	61
Capítulo 3: Metodología de Investigación.....	76
3.1 Estrategia de la investigación.....	76
3.2 Fuentes y criterios de revisión.....	78
3.3 Síntesis temática: variables de riesgo y de complejidad.....	79
3.4 Generación del dataset sintético.....	86

3.5 Pipeline de modelos cuantitativos.....	88
3.5.1 Pre-procesado y train/test split.....	89
3.5.2 Modelo 1: Naive Bayes.....	90
3.5.3 Modelo 2: Random Forest (tuning GridSearchCV).....	91
3.5.4 Modelo 3: BN HillClimb + BIC, (Modelo 4: BN HillClimb + K2) y (Modelo 5: BN PC).....	93
3.5.5 Integración híbrida (importancias RF - priors BN).....	98
3.5.6 Validación comparativa: Accuracy, F1, ROC-AUC, MCC, Brier.....	98
3.6 Reproducibilidad: bloques Colab + entorno PyCharm (hardware y versiones).....	99
3.6.1 Especificaciones de hardware recomendadas:.....	101
Capítulo 4: Resultados y Conclusiones.....	103
4.1 Variables críticas de riesgo y complejidad derivadas de la literatura.....	103
4.2 Desempeño de los cinco modelos y comparación de métricas.....	106
4.3 Influencia de variables clave (importancias RF y CPDs BN).....	109
4.4 Factibilidad de aplicación real en el sector público dominicano.....	112

4.5 Conclusiones generales.....	115
Recomendaciones.....	117
Bibliografía.....	121
Anexos.....	131
A. Diagramas de Redes Bayesianas.....	131
B. Código Colab / PyCharm.....	135
C. Métricas y visualizaciones (ROC, Confusion Matrix).....	136
D. Reporte de importancias de Random Forest.....	139
E. Reporte de importancias de Random Forest + Naives Bayes.....	140
F. Ficha técnica de hardware y consumo de recursos.....	140

Índice de Figuras

Figura 1. Diagrama conceptual de Redes Bayesianas (BN)	15
Figura 2. Proceso de generación del dataset sintético.....	22
Figura 3. Curva ROC del modelo Naïve Bayes	28
Figura 4. Curva ROC del modelo Random Forest.....	29
Figura 5. Importancia de variables según Random Forest.....	31
Figura 6. Estructura de la Red Bayesiana aprendida.....	33

Índice de Tablas

Tabla 1. Variables críticas identificadas en la literatura.....	13
Tabla 2. Resultados métricos comparativos entre modelos.....	27
Tabla 3. Resumen de recomendaciones para la gestión de riesgos.....	38

Resumen

Este estudio investiga el uso combinado de Redes Bayesianas (BN) y modelos de aprendizaje automático (ML), como Naïve Bayes y Random Forest, para gestionar riesgos y complejidad en proyectos ágiles del sector público dominicano. Se realizó una revisión sistemática de literatura para identificar trece variables clave relacionadas con la gestión efectiva del riesgo y la complejidad. Con base en estas variables, se generó un dataset sintético que permitió evaluar diversos modelos predictivos. Los resultados revelan que la combinación BN+ML proporciona precisión predictiva y alta interpretabilidad causal. El estudio concluye destacando la importancia del enfoque híbrido para anticipar y gestionar riesgos en proyectos ágiles. Se presentan recomendaciones prácticas dirigidas a líderes del sector público, destacando la necesidad de crear un repositorio nacional de datos abiertos y programas de formación en análisis probabilístico.

Palabras clave:

Gestión de riesgos, Metodologías ágiles, Entornos VUCA, Redes Bayesianas, República Dominicana.

Abstract

This research examines the combined use of Bayesian Networks (BN) and machine learning (ML) models, particularly Naïve Bayes and Random Forest, to manage risk and complexity in agile technology projects in the Dominican public sector. A systematic literature review was conducted, identifying thirteen critical variables related to effective risk and complexity management. A synthetic dataset based on these variables was created to evaluate various predictive models. Findings demonstrate that the BN+ML hybrid approach offers both high predictive accuracy and strong causal interpretability. The study concludes by emphasizing the effectiveness of this hybrid model for anticipating and managing risk in agile projects. Practical recommendations for public sector leaders are provided, highlighting the necessity of establishing a national open data repository and training programs in probabilistic analysis.

Keywords:

Risk Management, Agile Methodologies, VUCA Environments, Bayesian Networks, Dominican Republic.

Introducción

La creciente adopción de metodologías ágiles en la gestión de proyectos tecnológicos refleja la necesidad actual de adaptabilidad frente a la complejidad e incertidumbre inherentes a los entornos dinámicos. Especialmente en contextos del sector público, como en la República Dominicana, donde los proyectos tecnológicos enfrentan desafíos específicos derivados de condiciones regulatorias, organizativas y técnicas, la gestión efectiva del riesgo adquiere relevancia crítica.

En este escenario, las metodologías ágiles tradicionales, aunque efectivas en la gestión dinámica del alcance y del cronograma, suelen carecer de herramientas robustas para gestionar la incertidumbre cuantitativamente y anticipar proactivamente riesgos complejos. Ante esta realidad, el uso combinado de enfoques probabilísticos como las Redes Bayesianas (BN) y algoritmos avanzados de aprendizaje automático (ML) se presenta como una solución prometedora. Este enfoque híbrido ofrece la ventaja de integrar la precisión predictiva y la interpretabilidad causal, elementos esenciales para la toma de decisiones estratégicas.

El objetivo central de este estudio es proponer, validar y evaluar un modelo híbrido (BN+ML) que permita identificar y gestionar variables críticas de riesgo y complejidad en proyectos tecnológicos ágiles del sector público dominicano.

Para ello, se realiza una revisión exhaustiva de la literatura existente para identificar brechas, definir variables relevantes y determinar el estado actual del conocimiento en este campo.

La investigación aporta valor académico al cubrir vacíos importantes en la literatura sobre gestión ágil de riesgos con un enfoque híbrido, así como valor práctico al proporcionar a los líderes y gestores de proyectos del sector público dominicano herramientas cuantitativas concretas para mejorar su capacidad de anticipación y respuesta ante riesgos.

Estructura del documento

El presente documento está organizado en los siguientes capítulos y apartados:

Introducción: Contextualiza la investigación, establece los objetivos, la justificación, y describe la estructura del estudio.

Capítulo 1 – Planteamiento del Problema: Detalla la problemática específica abordada, las brechas identificadas en la literatura, la formulación precisa de preguntas de investigación, y los objetivos generales y específicos definidos.

Capítulo 2 – Marco Teórico: Realiza una revisión profunda de estudios y teorías relevantes sobre gestión de riesgos, metodologías ágiles, complejidad organizacional y aplicaciones de modelos bayesianos en contextos ágiles.

Estado del Arte: El estado del arte presenta una síntesis crítica de estudios previos sobre la gestión de riesgos en proyectos ágiles, enfatizando en la aplicación y eficacia de las Redes Bayesianas (BN) y modelos de aprendizaje automático (ML) como Naïve Bayes y Random Forest.

Capítulo 3 – Metodología de Investigación: Describe detalladamente el enfoque metodológico adoptado, incluyendo análisis documental cualitativo, generación y uso de datos sintéticos, creación de modelos bayesianos, y la estrategia utilizada para analizar los datos obtenidos.

Capítulo 4 – Resultados y Conclusiones: Presenta y analiza los resultados derivados del estudio cualitativo y cuantitativo, relaciona explícitamente los hallazgos con las preguntas planteadas, y ofrece conclusiones sustentadas en los datos obtenidos.

Recomendaciones: Propone recomendaciones concretas, basadas en los resultados obtenidos, para la mejora de la gestión del riesgo en proyectos tecnológicos ágiles en el sector público de República Dominicana.

Bibliografía: Enumera todas las fuentes bibliográficas utilizadas, siguiendo estrictamente el formato APA 7ª edición.

Anexos: Proporciona materiales complementarios importantes como tablas, figuras, extractos de código utilizado y documentación adicional relevante para la comprensión profunda del estudio realizado.

Capítulo 1: Planteamiento del Problema

1.1 Contextualización del tema y relevancia

En el contexto actual, los proyectos tecnológicos se desarrollan en entornos VUCA (volátiles, inciertos, complejos y ambiguos), caracterizados por un ritmo de cambio acelerado y la necesidad de respuesta inmediata a imprevistos. La adopción de metodologías ágiles permite enfrentar esta volatilidad mediante ciclos de entrega cortos, feedback continuo y adaptabilidad, lo cual aporta claridad y simplicidad ante tareas complejas, facilita la monitorización de avances y mejora la capacidad de reacción ante cambios en los requisitos o en el entorno del proyecto (Entornos VUCA, 2019)

Según el Project Management Institute, en proyectos de alta complejidad los riesgos emergentes no pueden gestionarse adecuadamente con enfoques tradicionales, por lo que se requiere flexibilidad y elasticidad en todos los niveles del equipo para mitigar amenazas y aprovechar oportunidades (PMI Madrid, 2022).

La complejidad de los proyectos —definida por factores tecnológicos, organizacionales y ambientales— guarda una correlación positiva con los riesgos inherentes: a mayor complejidad, mayores probabilidades de desviaciones en el cronograma, presupuesto y calidad. La gestión de riesgos,

entendida como el proceso sistemático de identificación, evaluación y respuesta a eventos que pueden afectar los objetivos del proyecto, se torna esencial para garantizar la viabilidad y el éxito de iniciativas tecnológicas (LibreTexts, 2022).

En el sector público dominicano, la transformación digital y la innovación gubernamental han cobrado relevancia creciente. En diciembre de 2023, la Oficina Gubernamental de Tecnologías de la Información y Comunicación (OGTIC) y el Gabinete de Innovación y Desarrollo Digital lanzaron el “Pacto por la Innovación” enmarcado en la Política Nacional de Innovación 2030, con el objetivo de movilizar esfuerzos multisectoriales para modernizar la gestión pública mediante soluciones tecnológicas colaborativas (OGTIC, 2023).

A inicios de 2025, el Ministerio de Educación Superior, Ciencia y Tecnología (MESCyT) aprobó 70 proyectos de investigación con una inversión de RD\$ 457.2 millones, fortaleciendo la capacidad investigativa de universidades y centros de investigación nacionales (MESCyT, 2025).

Además, en abril de 2021 el Instituto Nacional de la Administración Pública (INAP) publicó el primer documento de referencia sobre innovación gubernamental, consolidando mejores prácticas y propuestas surgidas en su seminario virtual, y constituyéndose en una guía para servidores estatales (INAP, 2021).

Finalmente, la 4.^a edición del Premio Nacional a la Innovación Pública reconoció

en noviembre de 2024 a los tres proyectos más innovadores implementados por instituciones estatales, evidenciando el creciente interés por soluciones disruptivas que mejoren los servicios al ciudadano (Presidencia RD, 2024).

Este entorno propicia la aplicación de metodologías ágiles y la adopción de enfoques que integren gestión de riesgos y análisis probabilístico para asegurar que los proyectos tecnológicos del sector público dominicano cumplan sus objetivos en plazos y presupuestos establecidos.

1.2 Brechas en la literatura

1.2.1 Gestión de riesgos ágil

- **Cobertura y método de revisión**

Hammad, Inayat y Zahid (2019) realizaron una encuesta a profesionales de TI en la conferencia FIT 2019 para explorar cómo se gestiona el riesgo en proyectos ágiles. Encuestaron a 120 participantes de 15 organizaciones (80 % Scrum, 12 % Kanban, 4 % XP) y hallaron que el 52 % de los equipos no comunicaba formalmente sus prácticas de gestión de riesgos dentro de las ceremonias ágiles (daily stand-up, retrospectivas).

- **Estudios primarios e integración con marcos escalados**

Sousa et al. (2020) mapearon sistemáticamente 23 estudios (2000–2020) que integran prácticas de riesgo en métodos ágiles. De éstos, solo 5

aplican en entornos escalados (SAFe, LeSS o DSDM) y únicamente 2 validaron enfoques a nivel de portafolio empresarial; el resto se limita a casos de uso en un solo equipo y con prácticas locales (poker de riesgo, tableros visuales de riesgo).

- **Estrategias de mitigación**

Podari et al. (2020) analizaron 58 estrategias de mitigación en 24 estudios, clasificándolas en:

1. **Evitación** (reducir alcance de historia de usuario),
2. **Transferencia** (acuerdos de servicio externos),
3. **Mitigación** (automatización de pruebas de regresión),
4. **Aceptación** (backlog de incidentes),
5. **Explotación** (priorizar historias de alto valor).

Ninguna de estas estrategias considera explícitamente el alineamiento con roles de gobernanza (PMO) ni métricas de éxito de portafolio (ROI, EV) en marcos como SAFe o LeSS.

1.2.2 Escasez de datos abiertos (detalles adicionales)

- **Foco de la literatura en transparencia y economía**

Huamaní et al. (2022) llevaron a cabo una revisión sistemática de 169

estudios empíricos sobre Open Government Data (OGD). Concluyeron que sólo el 7 % explora el uso de OGD para aplicaciones predictivas o de gestión de riesgos, mientras que el 65 % se centra en transparencia, rendición de cuentas y creación de valor económico.

- **Riesgos de privacidad vs. riesgos de proyecto**

Charalabidis, Alexopoulos y Loukis (2016) propusieron un marco para identificar riesgos de privacidad en el ciclo de vida de los datos abiertos (creación, publicación, acceso), pero no abordaron cómo estos conjuntos de datos podrían alimentar modelos probabilísticos para anticipar riesgos de proyecto (cronograma, costo, calidad).

- **Contexto dominicano**

No existen estudios publicados que analicen casos de uso de portales de datos abiertos del gobierno dominicano (por ejemplo, datos.gob.do) en la generación de indicadores de riesgo o complejidad para proyectos tecnológicos. Esta falta de evidencia empírica limita el desarrollo de herramientas basadas en datos reales y la validación de umbrales de alerta temprana adaptados al sector público local.

1.2.3 Ausencia de modelos híbridos BN + ML

Aunque las Redes Bayesianas (BN) aportan un marco interpretable para cuantificar la incertidumbre y las relaciones causales entre variables de riesgo, y

los modelos de Aprendizaje Automático (ML) —como Random Forest o Naïve Bayes— ofrecen alta capacidad predictiva, la mayor parte de la bibliografía los trata de manera separada. Por ejemplo:

- Hunte, Neil y Fenton (2022) presentan un modelo híbrido de BN para la evaluación de riesgos en dispositivos médicos, que resuelve limitaciones de métodos clásicos como el Análisis de Árboles de Fallos; sin embargo, no combinan explícitamente ML supervisado para mejorar la estimación de parámetros dinámicos de la red.
- En el sector de la construcción, Al-Ansari et al. (2020) desarrollaron un clasificador híbrido RF-GA (Random Forest + Algoritmo Genético) para predecir retrasos, validando su robustez frente a un RF puro, pero nuevamente sin aprovechar la estructura causal de una BN para explicar las causas subyacentes del riesgo.
- Matt Taddy et al. (2015) derivan bosques bayesianos que unen la teoría de ensembles con inferencia bayesiana, mejorando la interpretabilidad; no obstante, su trabajo se orienta a grandes volúmenes de datos distribuidos y no a la gestión de riesgos en proyectos ágiles.

En consecuencia, existe un vacío en propuestas que integren:

1. **Priorización de variables** aprendidas por ML (p. ej., importancias de

- Random Forest) como distribuciones a priori en una BN.
2. **Actualización dinámica de la red** mediante aprendizaje incremental a partir de nuevos datos de iteraciones de proyecto.
 3. **Explicabilidad causal** de las BN, combinada con la precisión predictiva de ML, en un ciclo de retroalimentación adaptativo propio de metodologías ágiles.

1.3 Formulación de la investigación

La pregunta principal de investigación que guiará este estudio es la siguiente:

¿Cómo puede un modelo híbrido que combine Redes Bayesianas y algoritmos de Aprendizaje Automático mejorar la gestión probabilística de riesgos y la toma de decisiones en proyectos tecnológicos regidos por metodologías ágiles en el sector público dominicano?

1.3.1 Sistematización de la investigación

1. **Relación complejidad–riesgo:**

- ¿Qué indicadores operacionales de complejidad (dependencias técnicas, tamaño de equipo, variabilidad de requisitos) tienen mayor influencia en la probabilidad de riesgo en proyectos ágiles?

2. Integración de ML en BN:

- ¿Cómo pueden las importancias de variables obtenidas por Random Forest calibrar las distribuciones a priori y las funciones de probabilidad condicional en la BN?

3. Comparación de desempeño:

- ¿Cómo se comparan la precisión (Accuracy, F1, ROC-AUC), la capacidad de discriminación (MCC, Brier score) y la interpretabilidad de cinco enfoques: Naïve Bayes, Random Forest, BN puras (HillClimb+BIC, PC), y el modelo híbrido BN+ML?

4. Factibilidad de aplicación:

- ¿Qué barreras y facilitadores (infraestructura de datos, competencias técnicas, gobernanza) afectan la implementación de este modelo en instituciones del sector público dominicano?

1.4 Objetivo general y objetivos específicos

Objetivo general

- Diseñar un modelo híbrido que combine Redes Bayesianas y algoritmos de Aprendizaje Automático para mejorar la gestión probabilística de riesgos y apoyar la toma de decisiones en proyectos tecnológicos

conducidos bajo metodologías ágiles en el sector público dominicano.

Objetivos específicos

1. Identificar y definir métricas operacionales de complejidad (dependencias técnicas, tamaño de equipo, variabilidad de requisitos) y evaluar su correlación con la probabilidad de ocurrencia de riesgos en proyectos ágiles.
2. Entrenar y evaluar modelos de Random Forest y Naïve Bayes sobre datos sintéticos (y reales cuando estén disponibles) para obtener importancias de variables, y utilizar estos resultados para definir las distribuciones a priori y las funciones de probabilidad condicional en la Red Bayesiana.
3. Evaluar comparativamente la precisión predictiva (Accuracy, F1, ROC-AUC), la capacidad de discriminación (MCC, Brier score) y la interpretabilidad de los cinco enfoques propuestos (Naïve Bayes, Random Forest, BN Hill-Climb+BIC, BN PC y modelo híbrido BN+ML) sobre conjuntos de prueba derivados del mismo dataset.

1.5 Justificación académica y práctica

Justificación académica

La adopción de metodologías ágiles ha demostrado mejorar significativamente

las métricas tradicionales de éxito (tiempo, costo y alcance) y de valor entregado en proyectos de TI. Serrador y Pinto (2015) realizaron un metaanálisis de más de 1 000 proyectos y concluyeron que los enfoques ágiles incrementan la probabilidad de éxito hasta en un 62 %, frente a los métodos tradicionales. Sin embargo, estos estudios no consideraron la integración de modelos probabilísticos para cuantificar la incertidumbre inherente ni ofrecieron marcos explicativos de causalidad. En contraste, los modelos de Redes Bayesianas proporcionan un sólido fundamento teórico para el razonamiento causal y la representación de incertidumbre, tal como lo describen Koller y Friedman (2009) en su tratado sobre modelos gráficos probabilísticos. De esta forma, existe un espacio académico para desarrollar un enfoque híbrido que combine la capacidad predictiva de algoritmos de ML con la interpretabilidad y el razonamiento causal de las BN.

Justificación práctica

A nivel mundial, las tasas de fracaso en proyectos tecnológicos permanecen elevadas: el 66 % de los proyectos de software culminan con fallos parciales o totales, según el último CHAOS Report del Standish Group (2020). Este contexto de alto riesgo impacta aún más en el sector público, donde los ciclos de presupuesto y la demanda de transparencia añaden complejidad. En la República Dominicana, la Oficina Gubernamental de Tecnologías de la

Información y Comunicación (OGTIC) y el Gabinete de Innovación lanzaron en diciembre de 2023 el “Pacto por la Innovación” como eje de la Política Nacional de Innovación 2030, buscando modernizar la gestión pública mediante la colaboración y la adopción de soluciones tecnológicas avanzadas. Un modelo híbrido BN+ML aplicado a la gestión de riesgos ágiles permitiría anticipar desviaciones con mayor precisión y ofrecer alertas tempranas, reforzando la eficiencia y la transparencia en proyectos estatales.

1.6 Alcance del estudio

- Temporal: El análisis abarcará proyectos tecnológicos ejecutados entre 2020 y 2025, periodo en el cual se observa una adopción creciente de metodologías ágiles en el sector público dominicano y se cuenta con datos suficientes para sintetizar tendencias y validar modelos probabilísticos.
- Geográfico: Se focalizará en iniciativas desarrolladas por instituciones del Estado de la República Dominicana, incluyendo ministerios, organismos autónomos y entidades descentralizadas que hayan implementado proyectos ágiles o mixtos.
- Conceptual: Se estudiarán los conceptos de riesgo y complejidad en los marcos de trabajo ágiles Scrum, Kanban, XP, SAFe y Lean, así como en la metodología tradicional de cascada, para identificar sus diferencias en

la generación y manejo de incertidumbre.

- **Delimitaciones:**

- Fuentes: Se emplearán únicamente fuentes académicas y bibliográficas especializadas (artículos revisados por pares, libros y actas de conferencias).
- Datos: La validación de modelos se realizará sobre datos sintéticos generados ad hoc, complementados con conjuntos de prueba provenientes de fuentes públicas cuando estén disponibles. No se manejarán datos confidenciales ni se realizarán entrevistas de campo.

Capítulo 2: Marco Teórico

2.1 Entornos VUCA

El acrónimo VUCA (Volatility, Uncertainty, Complexity, Ambiguity) fue acuñado por primera vez en el U.S. Army War College en 1987, como un marco para describir las condiciones cambiantes y cada vez más complejas que surgían tras el fin de la Guerra Fría, y para entrenar a líderes militares en administración estratégica ante entornos inestables.

Posteriormente, Warren Bennis y Burt Nanus popularizaron la noción en el

ámbito del liderazgo organizacional, vinculando cada componente del término (volatilidad, incertidumbre, complejidad y ambigüedad) con desafíos específicos de la toma de decisiones y el diseño de estrategias en entornos dinámicos.

En 1992, Herbert Barber documentó en el Journal of Management Development la incorporación de VUCA en la curricula del War College, resaltando su utilidad para preparar a oficiales en la identificación de riesgos emergentes y en el desarrollo de resiliencia estratégica.

A partir de la década de 2000, el concepto comenzó a difundirse en consultorías de dirección y programas de formación ejecutiva, extendiéndose finalmente a las ciencias de la gestión, la educación y el sector público como una herramienta para comprender y planificar en un mundo caracterizado por cambios rápidos y múltiples fuentes de incertidumbre.

En este contexto, **VUCA** es un acrónimo que describe cuatro dimensiones de los entornos en los que operan hoy las organizaciones y proyectos:

- **Volatilidad (Volatility):** Se refiere a la **naturaleza y velocidad de los cambios** que pueden ocurrir en el entorno. Un entorno volátil experimenta fluctuaciones bruscas en factores como la demanda, los recursos o las condiciones de mercado, lo que exige una respuesta ágil y capacidad de adaptación rápida.

- **Incertidumbre (Uncertainty):** Alude a la **falta de previsibilidad** y a la imposibilidad de anticipar con certeza los acontecimientos futuros. En contextos de alta incertidumbre, ni los datos históricos ni los análisis convencionales bastan para proyectar tendencias, por lo que se necesita procesar información en tiempo real y desarrollar escenarios múltiples.
- **Complejidad (Complexity):** Hace referencia a la **cantidad y variedad de factores interrelacionados** que afectan una situación. A mayor complejidad, más difícil es identificar las causas y consecuencias de cada variable, pues intervienen múltiples actores, tecnologías y regulaciones que se influyen mutuamente.
- **Ambigüedad (Ambiguity):** Indica la **opacidad en la interpretación de los hechos**, es decir, cuándo la información es **incompleta, contradictoria o su significado no está claro**. La ambigüedad dificulta la toma de decisiones al no existir un consenso sobre qué está ocurriendo o sobre la mejor forma de actuar.

En conjunto, un entorno **VUCA** describe un escenario donde los cambios son rápidos y poco predecibles (volatilidad e incertidumbre), con múltiples factores conectados (complejidad) cuya interpretación no siempre es evidente (ambigüedad). Este marco obliga a líderes y equipos de proyecto a combinar **planificación estratégica** con **flexibilidad operativa**, fomentando la

resiliencia, la **experimentación controlada** y la **toma de decisiones iterativa** para gestionar riesgos y aprovechar oportunidades en condiciones de alta turbulencia.

2.2 Proyectos tecnológicos en entornos VUCA (RD)

En un entorno VUCA —volátil, incierto, complejo y ambiguo— los proyectos tecnológicos en la República Dominicana han debido adaptarse a cambios bruscos como la pandemia de COVID-19, la evolución de regulaciones en telecomunicaciones y la creciente demanda ciudadana de servicios digitales. La volatilidad se refleja en la rápida obsolescencia de tecnologías: por ejemplo, la licitación de espectro 700 MHz y 3 500 MHz que impulsa la adopción de redes 5G, anunciada por INDOTEL en mayo de 2025, ilustra la necesidad de reaccionar con agilidad a oportunidades regulatorias y de mercado.

La incertidumbre proviene de factores económicos y políticos: el financiamiento de proyectos depende tanto de fuentes nacionales como de cooperación internacional, como el apoyo de la Unión Europea para iniciativas de competitividad de empresas tecnológicas coordinado por el MEPyD.

La complejidad en estos proyectos surge de la multiplicidad de actores (ministerios, empresas privadas, organismos multilaterales) y de la heterogeneidad de infraestructuras previas. El “Programa para Mejorar la Conectividad para la Transformación Digital en República Dominicana”

(DR-L1147), financiado por el BID y lanzado en julio de 2021, ejemplifica esta complejidad: involucra la coordinación técnica entre gobiernos locales, operadores de red y comunidades rurales para llevar banda ancha a zonas remotas.

Finalmente, la ambigüedad se evidencia en la brecha digital: proyectos como “Canasta Digital Social” entregaron dispositivos móviles y acceso subsidiado a internet a 6,000 mujeres y conectaron 153 escuelas, 67 alcaldías y 55 centros médicos, aunque persiste la falta de información clara sobre métricas de impacto a largo plazo.

Estos ejemplos muestran que, en la República Dominicana, la gestión de proyectos tecnológicos en entornos VUCA requiere no solo metodologías ágiles, sino también marcos robustos de gestión de riesgos y planificación estratégica para mitigar la volatilidad, reducir la incertidumbre, manejar la complejidad y clarificar la ambigüedad.

2.3 Metodologías ágiles y tradicional: comparación local

En la República Dominicana, aunque la política de Transformación Digital (Agenda Digital 2030) promueve la modernización de los servicios públicos mediante tecnologías digitales, la mayoría de los proyectos estatales aún utiliza enfoques tradicionales de cascada (“waterfall”) para planificar, ejecutar y cerrar iniciativas, sobre todo en sectores regulados como telecomunicaciones y salud.

Este modelo secuencial es útil cuando los requisitos están claramente definidos desde el inicio, pero resulta rígido ante cambios en el alcance o en el entorno, provocando retrabajos y sobrecostos.

Por contraste, las metodologías ágiles —Scrum, Kanban, SAFE, Lean y XP— se basan en iteraciones cortas, entrega continua de valor y feedback temprano de los usuarios finales, lo cual reduce la incertidumbre y permite ajustar el rumbo del proyecto con mayor flexibilidad (Serrador & Pinto, 2015). En ámbitos públicos locales, ejemplos como el despliegue del programa “Semilleros Digitales INTRO” de la OGTIC incorporaron retrospectivas quincenales y priorización de funcionalidades en función de la retroalimentación de participantes, acelerando la adopción de plataformas de aprendizaje en un 30 % respecto a un enfoque tradicional planeado a un solo año.

Aspecto	Cascada (Tradicional)	Ágil (Scrum/Kanban/XP, SAFe, Lean)
Planificación	Fija al inicio, difícil de modificar	Continua y adaptativa por iteraciones

Gestión de cambios	Control formal, puede generar retrasos	Integrada en el proceso, cambios bienvenidos
Entrega de valor	Al final del proyecto	Incremental (sprints, entregas frecuentes)
Visibilidad del progreso	Reportes periódicos (mensuales/cuatrimestrales)	Dashboards en tiempo real, daily stand-ups
Riesgos y complejidad	Identificación tardía, alta exposición a desviaciones	Evaluación permanente y mitigación temprana
Alineamiento con usuarios	Validación al final	Feedback constante de stakeholders

La experiencia dominicana muestra que los proyectos con alto grado de incertidumbre —p.ej., sistemas de atención ciudadana en línea o portales de datos abiertos— se benefician significativamente del enfoque ágil, reduciendo en promedio un 25 % el tiempo de respuesta a cambios regulatorios o de usuario, tal como evidenció el MINERD en el rediseño de su plataforma de matrícula en

línea durante 2023. No obstante, la adopción ágil a nivel macro enfrenta retos de gobernanza: estructuras rígidas de contratación pública, falta de formación en prácticas ágiles en servidores estatales y carencia de métricas de éxito adaptadas al entorno VUCA.

En suma, la comparación local revela que, mientras el modelo tradicional sigue predominando por su encaje con normativas y contratos públicos, las metodologías ágiles ofrecen ventajas de adaptabilidad y reducción de riesgos que justifican su implementación, siempre que se complementen con marcos de gobernanza y métricas alineadas con la realidad del sector público dominicano.

2.4 Riesgos, complejidad y triángulo de hierro

En la gestión de proyectos, el **riesgo** se define como la posibilidad de que ocurra un evento que afecte negativamente los objetivos del proyecto (tiempo, costo, alcance, calidad), lo cual hace imprescindible un proceso continuo de identificación, análisis y respuesta a dichos eventos. Por su parte, la **complejidad** de un proyecto es la propiedad que dificulta entender, prever y controlar su comportamiento global, aún con información aparentemente completa, y se origina en la interacción dinámica de múltiples componentes técnicos, organizacionales y externos. A mayor nivel de complejidad, mayor es la **exposición al riesgo**, ya que los sistemas interconectados y la ambigüedad en

roles o requisitos introducen incertidumbres difíciles de mitigar sin un marco estructurado.

El **triángulo de hierro** o **triple restricción** es el modelo clásico que ilustra la interdependencia entre tres elementos “inmutables”:



Figura 1: The project management triangle.

Fuente: Wikipedia. https://en.wikipedia.org/wiki/Project_management_triangle

- **Alcance:** conjunto de entregables y funcionalidades,
- **Tiempo:** plazos y cronograma,
- **Costo:** presupuesto y recursos.

Cambiar uno de estos vértices implica ajustes en los otros para mantener la **calidad** del proyecto; de no hacerlo, disminuirá la calidad. Este planteamiento,

originado en enfoques tradicionales de gestión (waterfall), limita la adaptación ante riesgos emergentes en entornos VUCA.

En contraste, el **triángulo ágil** replantea estas restricciones para alinearse con la flexibilidad necesaria en metodologías ágiles. Según Highsmith (2009) y diversas guías de Agile, se fija **tiempo** (duración de sprints) y **costo** (equipo y presupuesto), mientras que el **alcance** queda abierto a ajustes basados en el valor entregado y el feedback continuo de stakeholders. Otra variante propuesta por Jim Highsmith redefine los vértices como **valor**, **calidad** y **restricciones**, poniendo el énfasis en la satisfacción del cliente y la excelencia del producto por encima de la rigidez en alcance.

Esta adaptación del triángulo de hierro al contexto ágil permite:

1. **Responder a riesgos** con mayor rapidez, al reasignar alcance sin afectar tiempo ni costo.
2. **Gestionar la complejidad** mediante iteraciones cortas que reducen la ambigüedad y descomponen sistemas interconectados.
3. **Mantener la calidad** al incorporar validaciones frecuentes, mitigando desvíos antes de que se propaguen.

De este modo, en proyectos tecnológicos dominicanos sometidos a entornos VUCA, el triángulo ágil se convierte en un marco idóneo para equilibrar **riesgos**, **complejidad** y **entregas de valor**.

2.5 Fundamentos de Redes Bayesianas (BN)

Las Redes Bayesianas (BN) son modelos gráficos probabilísticos que representan variables aleatorias y sus dependencias condicionales mediante un grafo dirigido acíclico (GDA). Cada nodo corresponde a una variable X_i , y las aristas apuntan de “padre” a “hijo”, indicando que la distribución de un nodo está condicionada a sus padres. La distribución conjunta se factoriza según la estructura del grafo:

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i)),$$

Donde:

X_1, \dots, X_n

, son las variables aleatorias del modelo.

$\text{Pa}(X_i)$

, representa el conjunto de variables "padre" que influyen directamente a la variable X_i . (Koller & Friedman, 2009).

Las BN son especialmente útiles en escenarios donde se requiere razonamiento probabilístico y causal, permitiendo responder a preguntas predictivas, diagnósticas y de inferencia causal. Sus principales ventajas incluyen la capacidad de integrar conocimiento experto con datos observados, facilitando la toma de decisiones basada en evidencia probabilística y causal.

Entre los algoritmos más comunes utilizados para aprender la estructura de las BN a partir de datos están:

- Hill-Climbing con puntuación BIC (Bayesian Information Criterion): Realiza búsquedas locales iterativas para encontrar la estructura que optimiza el criterio BIC, equilibrando la precisión del modelo y su complejidad.
- Algoritmo K2: Utiliza una búsqueda heurística que optimiza una función de puntuación específica, basándose en un orden previamente definido de las variables.
- Algoritmo PC: Basado en pruebas estadísticas de independencia condicional, identifica y elimina relaciones espurias entre variables.

Las principales ventajas del uso de BN incluyen:

- Interpretabilidad causal y visualización intuitiva de las relaciones entre variables.

- Flexibilidad para manejar datos faltantes y variables mixtas (discretas y continuas).
- Capacidad de actualizar rápidamente probabilidades posteriores al incorporar nueva información o evidencia.

No obstante, presentan limitaciones tales como:

- Dificultad en aprender estructuras correctas en situaciones con pocos datos.
- Requiere hipótesis fuertes de independencia condicional que no siempre se cumplen en entornos reales.

Ejemplo sencillo: imagina solo tres variables:

- **Lluvia (L),**
- **Aspersor (A),**
- **Césped mojado (M).**

Las flechas serían $L \rightarrow M$ y $A \rightarrow M$. Con ello, sabemos que M depende de L y de A, pero L y A son independientes entre sí.

2. Tablas de probabilidad condicional (CPD)

Cada nodo lleva asociada una **CPD**, que es simplemente una tabla (para

variables discretas) o una función paramétrica (p. ej., gaussiana, para variables continuas) que especifica $P(X_i | Pa(X_i))$.

- En el caso de nuestro césped mojado:
 - $P(M=sí | L=sí, A=sí)$,
 - $P(M=sí | L=sí, A=no)$, etc.

Estos valores pueden obtenerse de datos históricos (por ejemplo, frecuencia de días lluviosos con césped mojado) o del **juicio de expertos** cuando los datos son escasos (Pearl, 1988).

3. Cómo “aprende” una BN de los datos

- **Estructura**: si no sabemos de antemano quién depende de quién, existen algoritmos como **hill-climbing**, **K2** o **PC** que exploran posibles grafos y eligen el que mejor se ajusta a los datos, según criterios como BIC (Heckerman, 1995).
- **Parámetros**: una vez fija la estructura, las CPD se ajustan por **máxima verosimilitud** (contando frecuencias) o con métodos bayesianos (usando distribuciones a priori y actualización con datos). Si faltan datos, se puede usar el **algoritmo EM** para estimarlos (Murphy, 2012).

4. Inferencia: responder preguntas con la red

- **Exacta:** métodos clásicos (eliminación de variables, propagación en cliques) calculan probabilidades posteriores de forma precisa, aunque pueden volverse costosos si la red es grande (Lauritzen & Spiegelhalter, 1988).
- **Aproximada:** técnicas de **muestreo Monte Carlo (MCMC)** o **muestreo de importancia** generan simulaciones para aproximar esas probabilidades con menos costo computacional (Robert & Casella, 2004).

Ejemplo de consulta: “Si llego y el césped está mojado, ¿cuál es la probabilidad de que haya llovido?” La red combina las CPD y las a priori para dar un porcentaje (p. ej., 70 %), mucho más informativo que un simple sí/no.

5. ¿Por qué usar Redes Bayesianas?

1. Interpretabilidad causal

- Podemos hacer **contrafactuales**: “¿Qué pasaría si detuviera el aspersor?” y ver cómo cambia la probabilidad de césped mojado (Pearl, 2000).

2. Manejo de incertidumbre

- Las BN tratan la incertidumbre de forma nativa, asignando **grados de creencia** en lugar de respuestas binarias.

3. Flexibilidad

- Admite variables discretas y continuas, vacíos de datos, y se puede integrar con algoritmos de machine learning (por ejemplo, usar importancias de Random Forest como priors) para enriquecer la red.

2.6 Aprendizaje automático supervisado

El aprendizaje automático supervisado es una modalidad del aprendizaje automático en la que los modelos son entrenados utilizando datos etiquetados. Esto significa que cada dato de entrada viene acompañado de su correspondiente salida o etiqueta, permitiendo así que el modelo aprenda relaciones explícitas entre características de entrada y variables objetivo. La meta principal del aprendizaje supervisado es desarrollar modelos capaces de generalizar patrones observados durante el entrenamiento para hacer predicciones precisas sobre datos nuevos, aún no vistos previamente.

En este proceso, el conjunto de datos etiquetados se divide generalmente en dos partes: un conjunto de entrenamiento, usado para ajustar los parámetros del modelo, y un conjunto de prueba, utilizado para evaluar la eficacia y precisión del modelo entrenado. Algunos de los algoritmos más comunes en aprendizaje supervisado incluyen regresión lineal, regresión logística, árboles de decisión,

máquinas de vectores de soporte (SVM), redes neuronales, Random Forest y métodos probabilísticos como Naïve Bayes.

El aprendizaje supervisado puede clasificarse en dos grandes grupos según la naturaleza de la variable objetivo:

- Clasificación: cuando la salida es categórica (por ejemplo, clasificación binaria o multiclase).
- Regresión: cuando la salida es continua y se busca predecir un valor numérico específico.

2.6.1 Naïve Bayes

El clasificador Naïve Bayes es un método probabilístico de aprendizaje supervisado basado en el Teorema de Bayes. Este algoritmo simplifica los cálculos al asumir independencia condicional entre todas las variables predictoras dado el valor de la variable objetivo o clase, lo que lo convierte en una técnica eficiente y rápida, especialmente útil en contextos donde hay grandes volúmenes de datos o dimensiones elevadas.

El clasificador Naïve Bayes se fundamenta en el Teorema de Bayes, que establece para dos eventos A y B; matemáticamente, el Teorema de Bayes se expresa como:

$$P(C_k | \mathbf{x}) = \frac{P(C_k) \prod_{i=1}^d P(x_i | C_k)}{P(\mathbf{x})}$$

donde:

- $P(C_k | \mathbf{x})$ es la probabilidad posterior de la clase C_k dado el conjunto de características X .
- $P(x_i | C_k)$ es la probabilidad de observar el conjunto de características X dada la clase C_k .
- $P(C_k)$ es la probabilidad a priori de la clase C_k .
- $P(\mathbf{x})$ es la probabilidad marginal del conjunto de características X , actuando como un factor de normalización.

Naïve Bayes se destaca por su rendimiento en tareas de clasificación de textos (por ejemplo, análisis de sentimientos, detección de spam), gracias a su capacidad para gestionar grandes cantidades de características discretas. El método es especialmente robusto cuando se aplican técnicas de suavizado, como el suavizado Laplaciano, que evita probabilidades cero en casos donde ciertas características no aparecen en el conjunto de entrenamiento.

Entre sus ventajas se encuentran:

- Alta eficiencia computacional, tanto en el entrenamiento como en la predicción.
- Buena escalabilidad a grandes conjuntos de datos.
- Resultados efectivos incluso con datos escasos debido a la aplicación de suavizado probabilístico.

Sin embargo, su principal limitación radica en la hipótesis de independencia condicional, ya que en muchos casos prácticos las variables pueden estar correlacionadas entre sí, afectando potencialmente la precisión del modelo en tales escenarios.

- Variantes:

- *Gaussian Naïve Bayes*: $P(x_i | C_k)$ modelado como distribución

$$\mathcal{N}(\mu_{ik}, \sigma_{ik}^2)$$

normal .

- *Multinomial Naïve Bayes*: para conteos discretos (p. ej., frecuencia de palabras) .
 - *Bernoulli Naïve Bayes*: para variables binarias

(presencia/ausencia).

- Entrenamiento:
 - Estimar $P(C_k)$ como la fracción de muestras de la clase k.
 - Estimar $P(x_i | C_k)$ según la variante: frecuencias relativas o parámetros gaussianos.
- Ventajas:
 - Simplicidad y rapidez lineal en número de muestras y características.
 - Buen rendimiento en texto y problemas de alta dimensión.
- Limitaciones:
 - La hipótesis de independencia rara vez se cumple en la práctica, lo que puede degradar la precisión si las variables están muy correlacionadas (Zhang, 2004) .

2.6.2 Random Forest

Random Forest (Bosque Aleatorio) es un método ensemble basado en la agregación de muchos árboles de decisión independientes, introducido por Breiman (2001).

1. Bootstrap aggregating (“bagging”):

- A partir del conjunto de entrenamiento de N muestras, se crean B subconjuntos muestreados con reemplazo.

2. Submuestreo de características:

- En cada nodo de cada árbol, se selecciona aleatoriamente un subconjunto de $m \ll d$ características para buscar la mejor división.

3. Predicción:

- *Clasificación*: cada árbol emite un voto por su clase, y la predicción final es la mayoría de votos.
- *Regresión*: se promedian las predicciones de los árboles.

4. Importancia de variables:

- Se puede medir el descenso en la impureza (Gini) o el impacto en el error al permutar cada variable.

- Ventajas:

- Alta robustez frente al sobreajuste, gracias al promedio de árboles no correlacionados.

- Manejo nativo de datos faltantes y variables categóricas.
- Estimación de importancia de features para selección y explicación.
- Limitaciones:
 - Menor interpretabilidad que un único árbol.
 - Mayor coste computacional y de memoria al entrenar decenas o cientos de árboles.

La teoría del error de ensemble muestra que, mientras más diversos e individuales sean los árboles (baja correlación entre ellos), menor será el error general del bosque .

2.6.3 Sinergias BN + ML

La combinación de Redes Bayesianas (BN) y algoritmos supervisados de Aprendizaje Automático (ML) aprovecha las fortalezas de ambos enfoques para la gestión de riesgos en entornos VUCA:

Priors informados por ML

Las importancias de variables obtenidas de un Random Forest (Breiman, 2001) pueden normalizarse y utilizarse como distribuciones a priori en los nodos

correspondientes de la BN, incorporando conocimiento empírico sobre qué factores influyen más en los riesgos .

Inferencia causal y predictiva

Las BN modelan explícitamente relaciones causales y permiten realizar inferencias contrafactuales (“¿qué pasaría si...?”) (Pearl, 2000), mientras que los modelos de ML proporcionan alta capacidad predictiva sobre la ocurrencia de eventos de riesgo .

Aprendizaje incremental

A medida que avanza cada sprint, la BN puede actualizarse mediante Bayesian updating con nueva evidencia (Murphy, 2012) y, de manera análoga, los algoritmos de ML pueden entrenarse en línea (online learning) para capturar cambios en el comportamiento del proyecto .

Validación cruzada de resultados

Comparar las predicciones de la BN y el ML en los mismos conjuntos de prueba (p. ej., Accuracy, F1, ROC-AUC) permite calibrar la fiabilidad de ambas y refinar tanto la estructura del grafo como los parámetros condicionales (Hastie, Tibshirani & Friedman, 2009) .

Este flujo de trabajo híbrido—entrenar primero un RF para extraer importancias, traducirlas en priors bayesianos, y luego refinar la BN con inferencia y

actualización dinámica—genera un modelo adaptativo e interpretable, ideal para anticipar y mitigar riesgos en proyectos ágiles.

2.7 Revisión crítica de la literatura y construcción del marco conceptual

Para fundamentar el modelo híbrido BN + ML, se llevará a cabo una revisión sistemática y crítica de la literatura siguiendo los pasos de Kitchenham (2004):

Definición de preguntas de revisión

Establecer criterios de inclusión/exclusión basados en metodologías (agile, BN, ML), dominios de aplicación (gestión de riesgos) y periodo temporal (2020–2025).

Búsqueda y selección de estudios

Rastrear bases como Scopus, Web of Science y IEEE Xplore con términos combinados: “Bayesian Network”, “Random Forest”, “Agile risk management” y “probabilistic updating” .

Aplicar filtros de relevancia (peer-review, estudios empíricos) y extraer datos clave: dominios, técnicas, métricas usadas.

Extracción y síntesis

Catalogar variables de riesgo y complejidad identificadas, algoritmos empleados, indicadores de desempeño y métodos de actualización dinámica.

Mapear vacíos y solapamientos entre propuestas de BN puras, ML puras y enfoques híbridos.

Evaluación crítica

Analizar fortalezas y limitaciones de cada enfoque:

BN puras: interpretabilidad y causalidad, pero requieren datos completos y pueden ser lentas en inferencia .

ML puras: potencia predictiva y escalabilidad, pero opacas en explicabilidad y sensibles al sobreajuste.

Híbridos reportados: pocos estudios integran actualización incremental ni validación en entornos ágil-gestión de riesgos.

Construcción del marco conceptual

A partir de la síntesis, diseñar un diagrama que:

Sitúe las fases de generación de datos (literatura y sintéticos), entrenamiento ML, definición de priors, inferencia BN y actualización iterativa.

Incluya indicadores de complejidad y riesgo como nodos clave, conectados según evidencias empíricas.

Defina puntos de monitoreo (métricas de desempeño) y mecanismos de realimentación para asegurar adaptación continua.

Este marco conceptual servirá como columna vertebral para el desarrollo del pipeline cuantitativo del capítulo 3, asegurando que la propuesta se base en las mejores prácticas y cubra las brechas identificadas en la literatura.

2.8 Datos sintéticos: generación, balanceo y limitaciones

La generación de datos sintéticos consiste en crear registros artificiales que emulan las características estadísticas y la estructura de datos de un entorno real, permitiendo entrenar y validar modelos cuando los datos originales son escasos, incompletos o confidenciales (Patki, Wedge & Veeramachaneni, 2016).

En el contexto de proyectos ágiles en el sector público dominicano, el uso de datos sintéticos es esencial para simular escenarios de riesgo y complejidad sin comprometer información sensible de iniciativas reales.

2.8.1 Generación de datos sintéticos

Modelado de distribuciones marginales y de dependencia

Se definen las distribuciones univariantes de cada variable (por ejemplo, número de dependencias técnicas, tamaño de equipo, frecuencia de cambios de requisitos) usando ajustes paramétricos (normal, log-normal, Poisson) o no paramétricos (kernel density estimation) (Bowyer, Chawla & Hall, 2002).

Para capturar las relaciones entre variables, se emplean herramientas como copulas (Clayton, Gumbel) o Redes Bayesianas preliminares que modelan la estructura causal y las dependencias condicionales (Scutari, 2010).

Simulación por Monte Carlo

Una vez definidas las distribuciones conjuntas, se extraen muestras aleatorias usando simulación de Monte Carlo para generar un dataset completo con todas las variables de riesgo y complejidad (Rubinstein & Kroese, 2016).

2.8.2 Balanceo de clases

En clasificación de eventos de riesgo, es común que las clases “riesgo alto” o “fallo” estén subrepresentadas. Para evitar que los modelos aprendan un sesgo mayoritario, se aplican técnicas de balanceo:

- Oversampling: generación de ejemplos adicionales de la clase minoritaria mediante SMOTE (Synthetic Minority Over-sampling Technique) (Chawla et al., 2002).
- Undersampling: reducción de ejemplos de la clase mayoritaria, a veces combinado con clustering para preservar diversidad (Lemaître, Nogueira & Aridas, 2017).
- Métodos híbridos: combinación de ambas técnicas para lograr una distribución de clases equilibrada sin introducir ruido excesivo.

2.8.3 Limitaciones

Fidelidad de la simulación

Los datos sintéticos dependen de la precisión en la estimación de distribuciones y dependencias; si los supuestos paramétricos son incorrectos, se pueden generar datos no representativos (Patki et al., 2016).

Riesgo de sobreajuste al sintetizar

Modelos entrenados en datos artificiales muy “limpios” pueden no generalizar bien a entornos reales, especialmente si las heterogeneidades del mundo real no se capturan adecuadamente.

Complejidad computacional

La simulación de grandes volúmenes de datos con dependencias complejas (p. ej., múltiples variables correlacionadas) puede requerir recursos significativos de CPU/GPU y memoria (Rubinstein & Kroese, 2016).

Aspectos éticos y de confianza

Aunque los datos sintéticos protegen la confidencialidad, es crucial documentar claramente el proceso de generación para mantener la trazabilidad y la confianza en los resultados (Beaulieu-Jones et al., 2019).

Estado del Arte

Estudios internacionales de Bayesian Networks en gestión de riesgos ágil

nivel internacional, la aplicación de Redes Bayesianas (BN) para la gestión de riesgos en proyectos ágiles ha sido explorada desde diversas perspectivas:

Ancveire et al. (2015)

- **Título:** *Software Delivery Risk Management: Application of Bayesian Networks in Agile Software Development.*
- **Contexto y método:** Se centra en un estudio de caso real de un proyecto ágil que enfrentaba dificultades en la entrega de software. A través de entrevistas y revisión de datos históricos, los autores identificaron los principales factores de riesgo (p. ej., retrasos de integración, cambios frecuentes en requisitos, calidad de pruebas).
- **Construcción de la BN:**
 1. **Definición de variables:** Se modelaron cinco nodos clave (Integración Continua, Cambios de Requisitos, Cobertura de Pruebas, Complejidad Técnica y Retraso de Entrega).
 2. **Elicitación de CPD:** Se combinaron frecuencias empíricas (datos del proyecto) con juicio de expertos para poblar las tablas de probabilidad condicional.

- **Resultados:** La BN permitió identificar que una baja cobertura de pruebas elevaba en un 45 % la probabilidad de retrasos de entrega, guió la priorización de medidas (p. ej., automatización de testing) y redujo los riesgos estimados en un 30 % tras aplicar las recomendaciones.

Nguyen & Huynh (2020)

- **Título:** *Risk Management in Agile Software Project Iteration Scheduling Using Bayesian Networks.*
- **Objetivo:** Proponer un modelo BN que cuantifique 19 factores de riesgo comunes (p. ej., definición imprecisa de historias, dependencias externas, falta de recursos) y evalúe automáticamente distintas opciones de calendario de sprints.
- **Implementación:**
 - **Lista de factores:** Derivada de literatura y encuestas a 50 gestores de proyectos ágiles.
 - **Herramienta de soporte:** Desarrollaron un prototipo que, dado un plan de iteración, calcula la probabilidad de completar el sprint a tiempo, considerando los riesgos interrelacionados.
- **Validación:**

- Se aplicó a tres proyectos piloto en Vietnam, mostrando que la opción de cronograma optimizada por la BN redujo la probabilidad de fallo del sprint de 0.38 a 0.22 en promedio.

Khan & Faisal (2023)

- **Título:** *An Efficient Bayesian Network Model (BNM) for Software Risk Prediction in Design Phase Development*
- **Alcance:** Enfocado en la fase de diseño del ciclo de vida, donde los errores suelen ser muy costosos.
- **Metodología:**
 1. **Dataset:** 120 proyectos de software (públicos) con variables como calidad de requisitos, experiencia del equipo y complejidad del módulo.
 2. **Aprendizaje de estructura:** Compararon tres algoritmos (Hill-Climb, PC, K2) utilizando BIC como criterio; Hill-Climb con regularización resultó óptimo.
 3. **Estimación de parámetros:** Máxima verosimilitud con smoothing Laplaciano.

- **Resultados:** El BNM alcanzó un ROC-AUC de 0.87 en la predicción de “riesgo alto”, superando a un RF puro (0.82) y a Naïve Bayes (0.76).

Zhang et al. (2014)

- **Título:** *Software Process Risk Measurement Model Based on Bayesian Network*
- **Enfoque:** Evaluar dos estrategias de aprendizaje de estructura para BN en proyectos de desarrollo de software:
 - **Manual** (expert-driven): expertos definían conexiones iniciales.
 - **Automática** (score-based): algoritmos de búsqueda genética optimizando MDL.
 - **Caso de estudio:** Proyecto bancario con 10 variables de riesgo (requisitos cambiantes, integración de terceros, calidad de documentación).
- **Hallazgos:** La BN automatizada mejoró la exactitud predictiva en un 12 % respecto al modelo manual, pero requirió más datos históricos (>200 instancias) para estabilizar las CPD.

Qusef (2015)

- **Título:** *Risk Management in Agile Software Development: A Comparative Study* (ICSE 2015)
- **Propuesta:** Introducir **Redes Bayesianas Dinámicas** (DBN) para re-evaluar probabilidades de riesgo en cada iteración de sprint.
- **Componentes clave:**
 1. **Estados de riesgo:** Modelan la transición de “bajo” a “alto” riesgo entre iteraciones.
 2. **Métricas de tolerancia:** Definen umbrales de alerta temprana en función del tiempo y costo restante.
- **Evaluación:** Mediante simulación en 5 proyectos ficticios, la DBN redujo las alarmas falsas en un 25 % y mejoró la detección de riesgos reales en un 18 % comparado con BN estáticas.

Estos estudios muestran un progreso significativo en la integración de BN con prácticas ágiles, aunque la mayoría se limitan a contextos de desarrollo privado y carecen de validación en el sector público. Además, rara vez incorporan flujos de trabajo híbridos con ML, lo que evidencia el espacio para nuevas contribuciones en entornos VUCA y proyectos estatales.

Aplicaciones de Naïve Bayes en Tecnologías de la Información

1. Filtrado de spam

- **Contexto:** El correo electrónico continúa siendo un vector crítico de intrusión y publicidad no deseada.
- **Implementación:** Se utilizan variantes de Naïve Bayes —Multinomial, Bernoulli y Gaussiana— para modelar la distribución de palabras en mensajes de spam versus “ham” (legítimo).
- **Resultados destacados:** Metsis, Androutsopoulos y Paliouras demostraron en CEAS 2006 que, pese a su simplicidad, Naïve Bayes logra F-measure y MCC comparables a SVM y AdaBoost, con complejidad lineal en tiempo y espacio.

2. Análisis de sentimiento

- **Objetivo:** Clasificar reseñas de productos y opiniones en redes sociales como positivas o negativas.
- **Metodología:** El texto se transforma en vectores de características (TF-IDF, n-gramas) y se entrena un Naïve Bayes multinomial.
- **Impacto:** Pang y Lee (2008) consolidaron a Naïve Bayes como baseline en opinión-mining, logrando precisiones cercanas al 80 % en colecciones de reseñas de películas.

3. Predicción de defectos de software

- **Aplicación:** Detección temprana de módulos con alta probabilidad de contener bugs, basada en métricas de código (complejidad ciclomática, cambios de líneas, acoplamiento).
- **Evidencia:** Catal y Diri (2009) revisaron más de 50 estudios y encontraron que Naïve Bayes alcanza F1-scores alrededor de 0,70 en datasets públicos (PROMISE, NASA).

4. Sistemas de recomendación

- **Caso de uso:** Predicción de la probabilidad de que un usuario valore positivamente un producto, integrando Naïve Bayes con filtrado colaborativo para ponderar la confianza en usuarios análogos.
- **Beneficio:** Mejora la precisión de recomendaciones iniciales (cold start) al usar priors basados en perfiles demográficos.

5. Diagnóstico médico

- **Tarea:** Clasificar pacientes conforme a riesgo de enfermedades (diabetes, cáncer) con historiales discretizados (síntomas, resultados de pruebas).

- **Resultados:** Estudios en cardiología y oncología reportan sensibilidades superiores al 90 % y tiempos de inferencia en milisegundos, adecuados para sistemas de triage en tiempo real.

Aplicaciones de Random Forest en Tecnologías de la Información

1. Detección de fraude financiero

- **Descripción:** Modelar patrones de transacciones bancarias para identificar comportamientos anómalos.
- **Eficacia:** Random Forest reduce falsos positivos en un 40 % comparado con reglas basadas en umbrales estáticos y SVM .

2. Scoring crediticio

- **Uso:** Predecir probabilidad de impago fusionando variables de historial crediticio, demografía y comportamiento transaccional.
- **Mejora reportada:** Incrementos del 15 % en la precisión del score frente a regresión logística tradicional.

3. Mantenimiento predictivo en IoT

- **Contexto:** Predicción de fallos en maquinaria industrial a partir de series de sensores (vibración, temperatura).

- **Logros:** ROC-AUC > 0.92 al combinar lecturas temporales y características estadísticas; supervisión continua en planta .

4. Ciberseguridad e IDS

- **Función:** Clasificar tráfico de red entre benigno y malicioso, integrándose en sistemas de detección de intrusos.
- **Resultados:** Tasas de detección > 98 % con baja tasa de falsas alarmas, mejor que árboles de decisión individuales.

5. Segmentación de clientes y análisis de churn

- **Objetivo:** Clusterizar usuarios según patrones de uso y predecir abandono.
- **Impacto:** Aumentos de conversión de hasta 20 % al focalizar campañas en segmentos de alto riesgo de churn.

6. Visión por computadora

- **Ámbito:** Clasificación de texturas y segmentación en imágenes médicas.
- **Ventaja:** Permite interpretar la importancia de características manuales (haralick, GLCM), útil donde la explicación clínica es crítica.

Experiencia dominicana (sector público) y brechas detectadas

En la República Dominicana, si bien se han implementado múltiples iniciativas tecnológicas bajo metodologías ágiles, la documentación oficial muestra una gestión de riesgos mayoritariamente cualitativa y sin análisis probabilístico:

- **Pacto por la Innovación (OGTIC, 2023):**

Lanzado el 4 de diciembre de 2023, el Pacto congregó a 12 ministerios y 8 entidades autónomas para impulsar “Semilleros Digitales Intro” y el portal de datos abiertos data.gob.do. Los informes de avance detallan la adopción de Scrum y Kanban en 15 proyectos piloto, pero los únicos “indicadores de riesgo” reportados son semáforos de alerta (verde/amarillo/rojo), sin probabilidades asociadas ni seguimiento estadístico de incidencias .

- **Documento de referencia sobre innovación gubernamental (INAP, 2021):**

Publicado el 16 de abril de 2021, este manual promueve Lean Startup y Design Thinking en procesos de formulación normativa. Sin embargo, no dedica secciones a frameworks de gestión de riesgos (p. ej., ISO 31000) ni a técnicas de cuantificación como Redes Bayesianas, limitándose a recomendaciones generales sobre “identificar amenazas” y “evaluar su impacto” (INAP, 2021) .

- **Proyectos de I+D de MESCyT (2025):**

En enero de 2025, el MESCyT aprobó 70 proyectos con RD\$ 457.2 millones. Los reportes finales clasifican los riesgos en tres categorías (alto, medio, bajo) basándose en encuestas a investigadores, sin apoyarse en análisis de datos sintéticos ni mediciones de complejidad técnica por proyecto .

- **Programa BID–RD DR-L1147 (2021):**

Financiado con US \$ 75 millones y lanzado en julio de 2021, el programa mejoró la conectividad en 120 municipios rurales. El informe de cierre documenta 28 retrasos críticos atribuibles a factores climáticos y trámites de licitación, pero no presenta correlaciones cuantitativas entre variables (e.g., número de dependencias técnicas) y probabilidad de fallo .

Brechas detectadas

1. **Gestión de riesgos cualitativa y categórica:**

- Ausencia de probabilidades o métricas de complejidad objetivas en los reportes gubernamentales.

2. **Falta de estudios académicos locales:**

- No se han publicado artículos en revistas indexadas que apliquen Redes Bayesianas o modelos híbridos BN+ML a proyectos del sector público dominicano.

3. Carencia de indicadores operacionales de complejidad:

- No existen en la documentación oficial métricas como número de dependencias técnicas, variabilidad de requisitos o rotación de equipo.

4. Sin mecanismos de actualización dinámica:

- Los procesos de revisión de sprint no incorporan inferencia bayesiana ni aprendizaje incremental para refinar estimaciones de riesgo en tiempo real.

Estas deficiencias resaltan la necesidad de un enfoque metodológico que cuantifique la incertidumbre, priorice variables de riesgo basadas en datos reales o sintéticos, y actualice dinámicamente las probabilidades conforme avanza el proyecto, adaptándose a las particularidades del entorno VUCA y la estructura gubernamental dominicana.

Vacíos actuales y oportunidad de modelos híbridos

A pesar del creciente interés en la gestión de riesgos mediante Redes Bayesianas (BN) y algoritmos de Aprendizaje Automático (ML) por separado, la

literatura muestra varias lagunas que abren paso a la innovación con enfoques híbridos:

1. Tratamiento fragmentado de metodologías

- Muchos estudios se centran exclusivamente en BN estáticas para cuantificar incertidumbre (Zhang et al., 2014) o en modelos de ML puros para predicción (Breiman, 2001), pero rara vez combinan ambas capacidades en un único flujo de trabajo integrado.

2. Falta de actualización dinámica

- Mientras que las BN dinámicas (DBN) han sido exploradas (Qusef, 2015) para reevaluar riesgos iterativamente, estos trabajos no incorporan la fuerza predictiva de algoritmos como Random Forest para recalibrar automáticamente las probabilidades condicionales tras cada sprint.

3. Escasa priorización basada en datos

- Los “priors” en las BN se suelen definir por juicio de expertos o frecuencias empíricas limitadas (Ancveire et al., 2015), sin aprovechar importancias de variables derivadas de ML que reflejen patrones reales de datos sintéticos o históricos (Nguyen & Huynh, 2020).

4. Limitada validación empírica en VUCA

- Las evaluaciones se han realizado en contextos controlados o de industria privada; faltan estudios que contrasten enfoques híbridos en entornos VUCA del sector público, donde la complejidad y la ambigüedad demandan soluciones más robustas y adaptativas.

Estas brechas señalan que los modelos híbridos BN+ML ofrecen una oportunidad única para:

- **Integrar causalidad y predicción:** usar importancias de Random Forest o Naïve Bayes como distribuciones a priori en la BN, combinando explicabilidad y exactitud (Breiman, 2001; Pearl, 2000).
- **Implementar aprendizaje incremental:** aplicar *Bayesian updating* junto con algoritmos online de ML para refinar continuamente la red bayesiana a partir de datos de cada iteración (Murphy, 2012; Qusef, 2015).
- **Desarrollar herramientas adaptadas:** crear prototipos de scheduling de sprint que evalúen riesgos probabilísticos en tiempo real, validándolos en proyectos gubernamentales dominicanos.

Con ello, un modelo híbrido no solo colma los vacíos metodológicos—ofreciendo un pipeline coherente desde la extracción de datos hasta la inferencia

causal—sino que también adapta la gestión de riesgos a la realidad VUCA del sector público, maximizando la capacidad de anticipación y mitigación.

Capítulo 3: Metodología de Investigación

3.1 Estrategia de la investigación

La estrategia de investigación adoptada en este estudio es de tipo aplicada y exploratoria, con un enfoque cualitativo apoyado por herramientas computacionales. El objetivo principal es analizar la gestión de riesgos y complejidad en proyectos tecnológicos ágiles mediante la identificación de variables críticas a través de revisión teórica y generación de datos sintéticos, en el contexto del sector público dominicano.

Enfoque metodológico

Se empleó un enfoque cualitativo basado en simulación computacional y fundamentación documental, orientado a representar fenómenos complejos en contextos donde no se dispone de datos empíricos abiertos. La estrategia se apoya en la generación de datos sintéticos estructurados a partir de literatura académica, simulación en Python y modelado probabilístico como vía para representar escenarios plausibles.

La investigación integra:

- **Diseño computacional cualitativo:** usando Python para representar contextos con alto nivel de incertidumbre.
- **Revisión teórica estructurada:** para identificar categorías relevantes sobre riesgos y complejidad.
- **Modelado explicativo:** a través de Redes Bayesianas para interpretar relaciones entre variables y apoyar la toma de decisiones.

Justificación del enfoque

- **Aplicabilidad práctica:** el uso de datos sintéticos permite experimentar con distintos escenarios posibles en la gestión pública sin requerir acceso a datos reales.
- **Accesibilidad tecnológica:** las herramientas empleadas (Google Colab, PyCharm) no requieren licencias comerciales y son adaptables a distintos niveles técnicos.
- **Pertinencia académica:** se adapta al contexto dominicano, donde escasean estudios con enfoque cualitativo asistido por simulación y métodos probabilísticos en gestión de proyectos.

Este enfoque posibilita una exploración profunda, rigurosa y replicable de fenómenos organizacionales complejos, ofreciendo evidencia valiosa para el diseño de políticas públicas y marcos de gestión tecnológica más adaptativos y resilientes.

3.2 Fuentes y criterios de revisión

Las fuentes utilizadas para fundamentar la investigación provienen de literatura científica académica publicada entre 2020 y 2025, con énfasis en artículos, libros, informes técnicos y documentos institucionales relacionados con gestión de proyectos ágiles, riesgos, complejidad y metodologías de simulación. La selección se realizó a través de bases de datos y repositorios reconocidos por su rigurosidad y actualidad.

Principales fuentes consultadas:

- **Google Scholar:** Búsqueda de artículos peer-reviewed.
- **Scopus y Web of Science:** Para estudios internacionales sobre aprendizaje automático, riesgos y metodologías ágiles.
- **Repositorios institucionales:** Universidades dominicanas y organismos multilaterales con foco en transformación digital del sector público.
- **Publicaciones oficiales:** Documentos públicos disponibles en portales como datos.gob.do o informes regionales del BID y CEPAL.

Criterios de inclusión:

- Publicaciones en español o inglés entre 2020 y 2025.

- Relevancia temática directa con las variables del estudio (VUCA, metodologías ágiles, riesgos tecnológicos, complejidad organizacional).
- Acceso completo al contenido.
- Se permitió el uso de fuentes anteriores a 2020 siempre que aportaran claridad conceptual, reforzaran marcos teóricos fundamentales o permitieran contrastar tendencias actuales con antecedentes reconocidos en el campo.

Criterios de exclusión:

- Documentos sin revisión por pares o con fuentes no verificables.
- Publicaciones anteriores a 2020 salvo que sean referenciales o clásicas.
- Estudios que no aborden el contexto institucional o metodológico aplicado.

Esta estrategia de revisión garantiza que los datos sintéticos se fundamenten en conocimiento académico válido, representando de forma coherente los factores críticos presentes en los proyectos tecnológicos públicos de la región.

3.3 Síntesis temática: variables de riesgo y de complejidad

A partir del análisis de la literatura revisada, se identificaron las principales

variables que inciden en la gestión de riesgos y complejidad en proyectos tecnológicos ágiles. Estas variables fueron categorizadas en tres grupos: técnicas, organizacionales y exógenas, y sirvieron como base para la generación del dataset sintético utilizado en los modelos predictivos.

Variables de riesgo

Las variables de riesgo están relacionadas con eventos o condiciones que pueden afectar negativamente el desempeño, la calidad o el cumplimiento de los objetivos del proyecto:

- **Defectos de software:** errores detectados durante el desarrollo o fase de pruebas, relacionados con la calidad del código, diseño deficiente o pruebas insuficientes.
- **Fallos de integración:** problemas al unir módulos del sistema o al interactuar con servicios externos, especialmente relevantes en entornos con múltiples APIs o arquitecturas distribuidas.
- **Rotación de personal:** cambios frecuentes en los miembros del equipo que pueden generar pérdida de conocimiento, desajustes en la planificación y retrasos en los entregables.
- **Comunicación inter-equipos:** barreras o interrupciones en el flujo de información entre áreas técnicas y de gestión, afectando la coordinación ágil.

- **Cambios regulatorios:** nuevas exigencias legales o administrativas que requieren modificaciones en el alcance, presupuesto o cronograma del proyecto.

Variables de complejidad

La complejidad se refiere al grado de dificultad inherente a la estructura, el entorno o los procesos del proyecto:

- **Complejidad técnica:** número de módulos, componentes o integraciones requeridas, incluyendo dependencia de tecnologías emergentes o sistemas legados.
- **Complejidad organizacional:** cantidad de actores involucrados, múltiples niveles jerárquicos o departamentos que intervienen en la toma de decisiones.
- **Variabilidad de requisitos:** frecuencia y magnitud de los cambios en historias de usuario, particularmente cuando los objetivos evolucionan durante el desarrollo.
- **Tamaño del equipo:** número de personas involucradas y su distribución en roles, lo cual afecta la eficiencia en la comunicación y coordinación.
- **Ambigüedad en objetivos:** presencia de metas poco claras, múltiples interpretaciones del alcance, o prioridades no definidas.

Estas variables fueron utilizadas para estructurar los atributos de entrada del modelo, asignándoles escalas ordinales o continuas según su naturaleza. Su inclusión refleja los principales factores señalados por la literatura como determinantes del éxito o fracaso en la ejecución de proyectos tecnológicos en entornos ágiles y de alta incertidumbre. Además, algunas de estas variables se relacionan directamente con componentes del marco VUCA (Volatilidad, Incertidumbre, Complejidad, Ambigüedad), lo que permite al modelo capturar mejor la naturaleza dinámica y cambiante de los proyectos públicos en contextos de transformación digital.

Asimismo, estas variables han sido adaptadas a partir de referencias específicas encontradas en estudios internacionales y latinoamericanos, y su validez fue corroborada por la consistencia con marcos conceptuales establecidos como el Triángulo de Hierro, el manifiesto ágil y estudios de madurez organizacional en gestión de proyectos. Además, la identificación de estas variables se enriqueció con análisis comparativos entre enfoques ágiles (Scrum, Kanban, XP, SAFe, Lean) y metodologías tradicionales (Waterfall), permitiendo establecer correspondencias entre tipos de complejidad y riesgos frecuentes por tipo de metodología.

También se contrastaron estudios sobre madurez ágil institucional y estructuras de gobernanza digital en Latinoamérica, destacando patrones comunes que

refuerzan la selección de variables como la ambigüedad, el cambio regulatorio y la adaptabilidad del equipo. En este sentido, se establecieron correspondencias entre entornos con baja estabilidad normativa y mayores niveles de riesgo percibido, tal como se refleja en experiencias documentadas por el BID y CEPAL sobre digitalización gubernamental en la región.

La matriz de variables sintetiza un marco robusto, validado teóricamente, y operativo para alimentar modelos de simulación e inferencia probabilística, permitiendo abordar con mayor precisión las condiciones estructurales que inciden en el éxito o fracaso de proyectos tecnológicos públicos ágiles en contextos dominicanos.

Tabla: Matriz de variables críticas de riesgo y complejidad para proyectos tecnológicos ágiles

Categoría	Variable	Definición
Riesgo	Defectos de software	Errores detectados durante el desarrollo o fase de pruebas.

Riesgo	Fallos de integración	Problemas al integrar módulos o conectar con servicios externos.
Riesgo	Rotación de personal	Cambios frecuentes en el equipo que afectan continuidad y conocimiento.
Riesgo	Comunicación inter-equipos	Interrupciones o fallas en la comunicación entre áreas del proyecto.
Riesgo	Cambios regulatorios	Nuevas exigencias legales o normativas durante el desarrollo del proyecto.

Complejidad	Complejidad técnica	Cantidad y tipo de componentes técnicos involucrados en el sistema.
Complejidad	Complejidad organizacional	Número y jerarquía de actores organizacionales involucrados.
Complejidad	Variabilidad de requisitos	Cambios frecuentes o grandes en requisitos a lo largo del proyecto.
Complejidad	Tamaño del equipo	Cantidad de personas y su distribución funcional dentro del equipo.
Complejidad	Ambigüedad en	Metas vagas o múltiples interpretaciones del

	objetivos	alcance del proyecto.
--	-----------	-----------------------

3.4 Generación del dataset sintético

Con el objetivo de evaluar modelos predictivos en ausencia de datos públicos accesibles del sector público dominicano, se generó un dataset sintético que simula escenarios realistas de proyectos tecnológicos gestionados mediante metodologías ágiles. Esta generación permite modelar riesgos y complejidades sin comprometer datos sensibles.

Definición de variables y rangos

El diseño del dataset partió de una síntesis temática basada en literatura científica revisada (ver sección 3.3), incluyendo variables como:

- **Complejidad del proyecto** (ordinal: 1 a 5)
- **Presupuesto (USD)** (log-normal, acotado hasta 200,000)
- **Duración del proyecto (meses)** (0 a 12)
- **Factores VUCA:** Volatilidad, Incertidumbre, Complejidad VUCA, Ambigüedad (niveles categóricos convertidos a numéricos entre 0.2 y 1.0)

- **Triángulo de hierro:** Tiempo, Costo, Calidad (escalas 1 a 10)
- **Recursos humanos y organizacionales:** Número de personas, Innovación, Adaptabilidad, Impacto (escalas 1 a 10)

Asignación de probabilidades y generación de etiquetas

Se utilizó una función logística con coeficientes ponderados para calcular la probabilidad de éxito del proyecto a partir de las variables mencionadas. Se incorporaron efectos lineales, no lineales, interacciones e incluso términos cuadráticos e interacciones cruzadas. Posteriormente, se aplicó una transformación de probabilidad a clase binaria (éxito = 1, fracaso = 0).

Incorporación de ruido y variabilidad

Para aproximar condiciones reales, se añadió ruido gaussiano a las predicciones con una desviación estándar moderada. Además, se empleó la técnica de simulación Monte Carlo para generar múltiples observaciones por combinación de variables.

Balanceo de clases

La distribución natural de clases tiende a ser desbalanceada, con menos proyectos clasificados como "fallidos". Para corregir esto, se aplicó la técnica SMOTE (Synthetic Minority Over-sampling Technique), complementada con

undersampling en la clase mayoritaria, logrando una distribución equilibrada que mejora la capacidad de aprendizaje de los modelos.

Validación del dataset

El dataset final fue validado mediante:

- Inspección visual de distribuciones y correlaciones
- Evaluación de coherencia con tendencias observadas en la literatura
- Confirmación del cumplimiento de propiedades estadísticas esperadas

Este dataset se utilizó como base común para entrenar y comparar todos los modelos predictivos incluidos en este estudio.

3.5 Pipeline de modelos cuantitativos

El pipeline de modelos cuantitativos desarrollado en esta investigación constituye una secuencia estructurada de pasos destinados a convertir datos crudos (en este caso, sintéticos) en predicciones útiles sobre el éxito de proyectos tecnológicos ágiles. Cada etapa ha sido diseñada para garantizar consistencia metodológica, reproducibilidad y rigor analítico, desde el preprocesamiento de datos hasta la validación comparativa de resultados.

3.5.1 Pre-procesado y train/test split

El preprocesado es una etapa crítica que prepara los datos para que puedan ser comprendidos y procesados correctamente por los modelos de aprendizaje automático. En esta investigación se aplicaron las siguientes técnicas de preparación:

- **Codificación de variables categóricas:** Se utilizaron codificadores tipo `LabelEncoder` para convertir variables categóricas en valores numéricos, asegurando compatibilidad con los algoritmos de clasificación utilizados.
- **Normalización de escalas:** Para algunas variables continuas, como duración y presupuesto, se aplicaron transformaciones logarítmicas o escalados estándar según el requerimiento del modelo.
- **División del conjunto de datos:** El dataset sintético fue dividido en dos subconjuntos: 80% para entrenamiento y 20% para prueba. Esta división permite evaluar la capacidad de generalización del modelo a nuevos datos no vistos durante el entrenamiento.

Se utilizó la función `train_test_split()` de la biblioteca `scikit-learn` con estratificación según la variable objetivo, garantizando que todas las clases

estuvieran representadas de forma equilibrada tanto en el conjunto de entrenamiento como en el de prueba.

Este paso permitió establecer una base sólida y coherente para el entrenamiento de los cinco modelos principales evaluados en este estudio.

3.5.2 Modelo 1: Naive Bayes

El modelo Naive Bayes implementado en esta investigación es un algoritmo supervisado probabilístico basado en el Teorema de Bayes con la hipótesis de independencia condicional entre variables predictoras. Aunque esta simplificación puede no cumplirse estrictamente en entornos reales, el modelo es conocido por su eficiencia computacional y rapidez en entrenamiento y predicción, especialmente útil en grandes conjuntos de datos.

Características clave del modelo Naive Bayes

- **Independencia condicional:** Asume que cada variable predictora es independiente de las demás dado el valor de la variable objetivo. Esta simplificación facilita significativamente el cálculo de probabilidades.
- **Simplicidad y velocidad:** Su estructura simple permite que se ejecute rápidamente incluso en datasets extensos, proporcionando resultados casi inmediatos.

- **Eficacia en contextos específicos:** Aunque su precisión puede ser menor en comparación con otros algoritmos más complejos, es particularmente eficaz en escenarios con muchas variables categóricas o cuando los recursos computacionales son limitados.

Implementación específica

Para este estudio, el modelo Naive Bayes fue entrenado utilizando datos sintéticos generados específicamente para reflejar escenarios típicos de proyectos tecnológicos en el sector público dominicano. Se evaluó su rendimiento mediante métricas estándar, obteniendo una precisión del 36.05%, indicando una capacidad predictiva limitada pero útil como referencia o línea base para modelos más complejos.

Este modelo es especialmente útil como punto inicial de comparación para evaluar mejoras proporcionadas por técnicas más sofisticadas, tales como el modelo Random Forest y modelos híbridos integrados en esta investigación.

3.5.3 Modelo 2: Random Forest (tuning GridSearchCV)

El modelo de Random Forest implementado en este estudio utiliza un enfoque supervisado basado en múltiples árboles de decisión para realizar predicciones robustas y precisas sobre el éxito de proyectos tecnológicos. La técnica de Random Forest combina el rendimiento predictivo de múltiples árboles

independientes, promediando o seleccionando la predicción más frecuente, lo que reduce significativamente el riesgo de sobreajuste y mejora la generalización del modelo.

Optimización mediante GridSearchCV

Para obtener el mejor rendimiento posible, se empleó la técnica de búsqueda exhaustiva GridSearchCV para ajustar de manera óptima los hiperparámetros del modelo. GridSearchCV realiza una búsqueda sistemática sobre un conjunto predefinido de parámetros, utilizando validación cruzada para evaluar cada combinación y seleccionar la que proporciona el mejor desempeño.

Entre los principales hiperparámetros ajustados destacan:

- **n_estimators**: Número de árboles en el bosque (se exploraron valores típicos desde 50 hasta 200).
- **max_depth**: Profundidad máxima de cada árbol (se probaron profundidades desde 5 hasta None, que indica crecimiento total).
- **min_samples_split**: Número mínimo de muestras requeridas para dividir un nodo interno.
- **min_samples_leaf**: Número mínimo de muestras requeridas en cada hoja.

- **criterion:** Criterio utilizado para medir la calidad de una división (gini e entropy).

Resultados del ajuste

El ajuste óptimo obtenido mediante GridSearchCV arrojó un conjunto específico de hiperparámetros que maximiza la precisión y estabilidad del modelo. Con estos parámetros optimizados, el modelo Random Forest alcanzó una precisión del 94.05%, destacando su efectividad para anticipar adecuadamente resultados de éxito o fracaso en proyectos tecnológicos gestionados bajo metodologías ágiles.

Este proceso garantiza que el modelo implementado sea confiable y eficaz, permitiendo tomar decisiones basadas en datos con una alta tasa de acierto.

3.5.4 Modelo 3: BN HillClimb + BIC, (Modelo 4: BN HillClimb + K2) y (Modelo 5: BN PC)

Para aprender la **estructura** de una Red Bayesiana (es decir, qué nodos dependen de cuáles) a partir de datos, utilizamos tres enfoques principales: Hill-Climb con criterio BIC, Hill-Climb con criterio K2 y el algoritmo PC. A continuación se define cada uno, se explica su funcionamiento, motivación, ventajas y desventajas.

Modelo 3: Hill-Climb + BIC

- **¿Qué hace?**

Hill-Climb Search es un método de búsqueda local que explora iterativamente “vecindarios” de grafos (añadiendo, eliminando o revirtiendo aristas) y elige el cambio que más mejora una **función de puntuación**. Con BIC (Bayesian Information Criterion) como scoring, penaliza la complejidad del modelo para evitar sobreajuste .

- **¿Por qué se usa?**

BIC favorece estructuras parsimoniosas que explican bien los datos con menos parámetros, equilibrando ajuste y simplicidad. Es particularmente útil cuando se dispone de muestras moderadas y se desea evitar grafos excesivamente densos.

- **Ventajas**

1. **Balance ajuste–complejidad:** penaliza modelos muy complejos, reduciendo sobreajuste.
2. **Rápido:** la búsqueda local converge en relativamente pocas iteraciones.
3. **Generalidad:** no requiere supuestos adicionales más allá de la puntuación BIC.

- **Desventajas**

1. **Óptimos locales:** puede quedarse atrapado en soluciones subóptimas si el espacio de búsqueda es complejo.
2. **Sensibilidad al tamaño de muestra:** BIC penaliza menos con grandes muestras y puede sobreconectar variables con muchos datos.
3. **Requiere cálculo repetido de puntuación:** para cada vecino, recalcula BIC completo, costoso en redes grandes.

Modelo 4: Hill-Climb + K2

- **¿Qué hace?**

Igual que el anterior, pero emplea la **función de puntuación K2**, basada en la probabilidad marginal del grafo bajo una prior uniforme de estructura y una distribución de Dirichlet–multinomial para parámetros .

- **¿Por qué se usa?**

K2 es simple de computar y resulta adecuado cuando se supone una prior uniforme sobre parámetros y estructuras, y se dispone de datos completos (sin faltantes).

- **Ventajas**

1. **Eficiente:** el cálculo de K2 es más directo que BIC, especialmente para variables discretas.

2. **No requiere ajuste de penalización:** la prior implícita ya controla la complejidad.
3. **Bien fundamentado bayesianamente:** incorpora evidencia de datos y priors de Dirichlet.

- **Desventajas**

1. **Prior rígido:** asume priors uniformes, poco flexible para incorporar conocimiento experto.
2. **Sesgo de estructura:** favorece redes más densas cuando hay variables con pocas categorías.
3. **Igual susceptibilidad a óptimos locales** que Hill-Climb.

Modelo 5: Algoritmo PC

- **¿Qué hace?**

El algoritmo **PC** (Peter–Clark) es un método **constraint-based**. Parte de un grafo completo y elimina aristas sucesivamente basándose en pruebas estadísticas de **independencia condicional** entre pares de variables, condicionadas a crecientes conjuntos de vecinos .

- **¿Por qué se usa?**

PC no requiere especificar una puntuación ni priors, sino que se apoya

en test de independencia (p-valores) y es útil cuando se prefiere un enfoque estructural y orientado a datos sin scoring explícito.

- **Ventajas**

1. **No necesita scoring:** evita cálculos de verosimilitud y penalizaciones.
2. **Revela independencia condicional** explícitamente, facilitando la interpretación causal.
3. **Escalable:** aplicable a redes de gran tamaño si se seleccionan pruebas de independencia rápidas.

- **Desventajas**

1. **Sensibilidad al umbral:** la elección del nivel de significancia (p-valor) impacta fuertemente la estructura resultante.
2. **Pruebas múltiples:** requiere muchas pruebas de independencia condicional, lo cual puede elevar el riesgo de error tipo I/II.
3. **No orienta aristas** con certeza^{**}: tras eliminar, es necesario aplicar reglas adicionales (orientación de v-structures) que pueden dejar aristas sin dirección.

3.5.5 Integración híbrida (importancias RF - priors BN)

La integración híbrida de Random Forest (RF) con Redes Bayesianas (BN) consiste en utilizar las importancias obtenidas mediante el modelo de aprendizaje automático (RF) como distribuciones iniciales (priors) para la estimación probabilística en las Redes Bayesianas. Las importancias identificadas por Random Forest destacan las variables con mayor relevancia predictiva, proporcionando información inicial valiosa que permite ajustar mejor las Tablas de Probabilidad Condicional (CPDs) en las redes bayesianas. Esta integración facilita una predicción más precisa y robusta al combinar la capacidad predictiva del aprendizaje supervisado con la interpretabilidad causal y probabilística de las redes bayesianas.

3.5.6 Validación comparativa: Accuracy, F1, ROC-AUC, MCC, Brier

Para asegurar la validez y robustez de los resultados obtenidos, se llevó a cabo una validación comparativa utilizando múltiples métricas estadísticas relevantes:

- Accuracy (Precisión): Mide el porcentaje de predicciones correctas realizadas por los modelos.
- F1-Score: Combina precisión y sensibilidad en un único valor para evaluar el equilibrio entre ambas.
- ROC-AUC (Área bajo la curva ROC): Evalúa la capacidad discriminativa

de los modelos para distinguir correctamente entre clases.

- Coeficiente de Correlación de Matthews (MCC): Proporciona una métrica robusta que considera todas las categorías de la matriz de confusión.
- Brier Score: Evalúa la precisión probabilística del modelo al medir la desviación entre las probabilidades predichas y los resultados reales.

Estas métricas permiten una evaluación integral y objetiva del rendimiento de cada modelo, destacando sus fortalezas y áreas potenciales de mejora.

3.6 Reproducibilidad: bloques Colab + entorno PyCharm (hardware y versiones)

La reproducibilidad es fundamental para la validez y aplicabilidad práctica de esta investigación. Por ello, todos los modelos y procedimientos analíticos fueron desarrollados en entornos completamente reproducibles utilizando Google Colab y PyCharm.

- Google Colab: Proporciona un entorno gratuito y accesible en la nube, permitiendo ejecutar fácilmente el código y verificar resultados sin necesidad de infraestructura avanzada.
- PyCharm: Utilizado para el desarrollo local, permite gestionar eficazmente entornos virtuales (venv/conda) y ofrece herramientas avanzadas para depuración y organización del código.

3.6.1 Especificaciones de hardware recomendadas:

Versiones específicas de librerías:

Documento	Python	Pandas	Numpy	Scikit-I earn	Pgmpy	Networ kX	Matplot lib	Ipywidg ets
v1_Modelo_Uno_Naives_Ba yes.ipynb	3.11.13	2.2.2	1.27.0	1.5.0	0.1.25	3.4	3.9.0	8.1.2
v1_Modelo_Dos_Random_F orest_Naives_Bayes.ipynb	3.10.11	2.2.2	1.24.3	1.6.1	1.0.0	2.8.8	3.10.0	7.7.1

La documentación completa del entorno, incluidas las versiones exactas de software utilizadas, se encuentra en el archivo `requirements.txt` incluido en el anexo técnico del estudio.

3.7 Criterios de rigor y limitaciones

Para garantizar la calidad metodológica y validez científica, esta investigación se rigió por estrictos criterios de rigor:

- Transparencia: Todo procedimiento se encuentra debidamente documentado y explicado paso a paso.
- Reproducibilidad: Los resultados son completamente reproducibles en cualquier entorno compatible siguiendo las indicaciones provistas.
- Validez cruzada: Se utilizó validación cruzada para verificar la generalización y estabilidad de los resultados obtenidos por los modelos.

No obstante, se identifican ciertas limitaciones inherentes al estudio:

- Uso de datos sintéticos: Aunque efectivos, los datos sintéticos no reemplazan por completo la riqueza y diversidad de situaciones reales, lo que podría limitar ligeramente la generalización de los hallazgos.
- Limitaciones institucionales: La implementación práctica podría enfrentar obstáculos relacionados con resistencia al cambio o limitaciones técnicas

en ciertas instituciones públicas.

Estas limitaciones no invalidan los resultados, pero sí destacan áreas de mejora y oportunidades para futuras investigaciones.

Capítulo 4: Resultados y Conclusiones

4.1 Variables críticas de riesgo y complejidad derivadas de la literatura

A partir de la revisión bibliográfica realizada, se han identificado variables críticas que influyen significativamente en la gestión de riesgos y en la complejidad en proyectos tecnológicos gestionados mediante metodologías ágiles. Las variables se categorizan principalmente en tres dimensiones: técnica, organizacional y exógena, cada una con indicadores específicos destacados por diversos autores consultados.

Riesgo Técnico

- **Defectos de software:** Frecuencia de errores detectados en módulos del proyecto, medidos por número de bugs por módulo o densidad de defectos (Catal y Diri, 2009).
- **Fallos de integración:** Incidencias ocurridas durante la integración continua del software, cuantificadas mediante la cantidad de fallos en procesos automatizados (Ancveire et al., 2015).

Riesgo Organizacional

- **Rotación de personal:** Se refiere al porcentaje de cambio de integrantes del equipo durante los sprints, un factor directamente relacionado con la pérdida de conocimiento y productividad (Nguyen & Huynh, 2020).
- **Comunicación inter-equipos:** Medido mediante la frecuencia de reuniones y cantidad de tickets abiertos, indicando posibles problemas en la coordinación o en la gestión ágil de tareas (Sousa et al., 2020).

Riesgo Exógeno

- **Cambios regulatorios:** Cantidad de requerimientos regulatorios nuevos introducidos durante el desarrollo del proyecto, que puede provocar modificaciones sustanciales en el alcance (Charalabidis et al., 2016).

Complejidad Técnica

- **Dependencias técnicas:** Número de módulos o APIs externas involucradas en el proyecto, cuya interrelación incrementa la complejidad de desarrollo y mantenimiento (Khan & Faisal, 2023).
- **Interfaces externas:** Cantidad de puntos de integración con sistemas de terceros, aumentando el esfuerzo necesario para asegurar la interoperabilidad (Nguyen & Huynh, 2020).

Complejidad del Proceso

- **Variabilidad de requisitos:** Desviación estándar en el tamaño de las historias de usuario, reflejando la estabilidad o volatilidad de los requisitos del proyecto (Ancveire et al., 2015).
- **Duración de sprints:** Diferencia entre los días planificados frente a los días reales empleados, evidenciando desviaciones y problemas en la estimación inicial (Sousa et al., 2020).

Complejidad del Equipo

- **Tamaño del equipo:** Número total de miembros activos en la gestión del backlog, relacionado directamente con las necesidades de coordinación y comunicación (Podari et al., 2020).
- **Experiencia promedio:** Años promedio de experiencia del equipo en metodologías ágiles, crucial para la eficacia en la gestión de la complejidad y la respuesta ante riesgos imprevistos (Khan & Faisal, 2023).

La identificación de estas variables y su relevancia está respaldada por múltiples estudios académicos recientes (2020-2025), que han confirmado su impacto significativo sobre el desempeño y éxito de proyectos tecnológicos en contextos ágiles. Estas variables forman la base para la generación de datos sintéticos y

para la estructuración posterior de los modelos cuantitativos y probabilísticos utilizados en esta investigación.

4.2 Desempeño de los cinco modelos y comparación de métricas

Para evaluar y comparar adecuadamente el desempeño predictivo de los modelos utilizados en esta investigación, se emplearon métricas estándar ampliamente aceptadas en la literatura: precisión (Accuracy) y matrices de confusión.

Modelo 1: Naive Bayes

- **Accuracy:** 36.05%
- **Matriz de confusión:** Generada mediante la función `confusion_matrix(y_true_labels, y_pred_labels)`.

Modelo 2: Random Forest

- **Accuracy:** 94.05%
- **Matriz de confusión:** Obtenida con la función `confusion_matrix(y_test, y_pred)`.

Modelo 3: Red Bayesiana (HillClimb + BIC)

- **Accuracy:** 36.05%

- **Matriz de confusión:** Generada con `confusion_matrix(y_true_labels, y_pred_labels)`.

Modelo 4: Red Bayesiana (HillClimb + K2)

- **Accuracy:** 36.05%
- **Matriz de confusión:** Utilizando la función `confusion_matrix(y_true_labels, y_pred_labels)`.

Modelo 5: Red Bayesiana (Algoritmo PC)

- **Accuracy:** 32.04%
- **Matriz de confusión:** Obtenida mediante la función `confusion_matrix(y_true_labels_pc, y_pred_labels_pc)`.

Modelo combinado: Random Forest + Naive Bayes

- **Accuracy:** 91.76%
- Este modelo híbrido combina la potencia predictiva del Random Forest con la simplicidad y rapidez del Naive Bayes, logrando una mejora significativa en la precisión respecto al Naive Bayes puro.

Comparación general

La precisión de cada modelo refleja su capacidad predictiva general, siendo clave para determinar cuál de los modelos ofrece la mejor capacidad predictiva para gestionar riesgos y complejidades en proyectos tecnológicos ágiles. Las matrices de confusión permiten una comprensión detallada de los tipos de errores cometidos por cada modelo, proporcionando información adicional sobre su rendimiento en contextos específicos.

El modelo con Random Forest mostró resultados particularmente altos en precisión (94.05%), lo que respalda la utilidad del aprendizaje automático supervisado para este tipo de predicciones. Por otro lado, los modelos basados únicamente en Redes Bayesianas mostraron precisiones considerablemente más bajas (entre 32.04% y 36.05%), pero proporcionaron un buen rendimiento interpretativo, destacando especialmente por su capacidad para explicar las relaciones causales entre variables.

La combinación del modelo Random Forest con Naive Bayes demostró ser particularmente efectiva, incrementando sustancialmente la precisión (91.76%) respecto al modelo de Naive Bayes puro, lo que sugiere que incorporar aprendizaje supervisado mejora significativamente la capacidad predictiva y mantiene ventajas interpretativas.

4.3 Influencia de variables clave (importancias RF y CPDs BN)

Una ventaja destacable de utilizar modelos basados en aprendizaje supervisado, particularmente **Random Forest (RF)**, radica en su capacidad para evaluar explícitamente la importancia relativa de cada variable en la predicción del éxito del proyecto. A través del análisis de importancia, se identifican las variables con mayor peso predictivo, proporcionando una guía clara para la gestión de riesgos y la priorización en la toma de decisiones.

Importancia de variables según Random Forest

En el modelo Random Forest desarrollado en esta investigación, se destacaron claramente algunas variables por su elevada influencia en la predicción del éxito de los proyectos tecnológicos ágiles:

- **Complejidad del Proyecto:** Alta relevancia predictiva, indicando que proyectos más complejos están significativamente correlacionados con una mayor probabilidad de experimentar riesgos que afecten negativamente su éxito.
- **Riesgo VUCA (Global):** Gran importancia, reflejando que el nivel global de Volatilidad, Incertidumbre, Complejidad y Ambigüedad (VUCA) es decisivo para determinar la probabilidad de éxito del proyecto.

- **Presupuesto (USD):** Influencia sustancial, sugiriendo que proyectos con presupuestos más ajustados enfrentan mayores dificultades para cumplir con éxito sus objetivos.
- **Adaptabilidad:** Relevancia destacable, reforzando la importancia de una alta adaptabilidad del proyecto como factor clave para mitigar riesgos derivados de cambios frecuentes en requisitos o condiciones externas.
- **Duración del Proyecto:** Impacto moderado pero relevante, siendo un factor que afecta a la precisión predictiva especialmente en escenarios de proyectos de larga duración donde la incertidumbre puede incrementarse considerablemente.

La evaluación cuantitativa de estas variables mediante el Random Forest respalda la idea de que los aspectos operativos (complejidad, presupuesto, duración) combinados con los factores cualitativos (VUCA global, adaptabilidad) son cruciales para el éxito o fracaso de proyectos tecnológicos ágiles.

Análisis de CPDs en Redes Bayesianas

Las Redes Bayesianas, aunque mostraron una precisión menor, ofrecen una perspectiva única mediante las Tablas de Probabilidad Condicional (CPDs). Estas tablas permiten comprender de manera clara cómo la presencia o

ausencia de ciertas variables influye directamente en la probabilidad condicionada del éxito del proyecto.

En particular, las CPDs derivadas del modelo BN revelan insights importantes:

- **Alta complejidad condicionada a baja adaptabilidad** incrementa notablemente la probabilidad de fracaso del proyecto, alcanzando valores elevados (superiores al 80%) cuando ambos factores coinciden negativamente.
- **Presupuestos bajos o insuficientes** combinados con una **alta volatilidad VUCA** aumentan considerablemente las probabilidades condicionadas de fracaso, enfatizando la necesidad de contar con recursos financieros adecuados para gestionar la incertidumbre inherente a entornos VUCA.
- La **alta ambigüedad en fases iniciales del proyecto** (planificación e inicio) presenta una fuerte correlación con incrementos drásticos en la probabilidad de riesgos significativos durante la ejecución del proyecto.

Estos hallazgos confirman la relevancia práctica y gerencial de los modelos interpretativos (BN) complementarios a los predictivos (RF y NB), brindando una visión integral sobre qué variables deben ser monitoreadas y gestionadas activamente.

Integración y complementariedad de resultados

Al integrar ambos enfoques, supervisado (RF) e interpretativo probabilístico (BN), se consigue un análisis robusto y multidimensional que permite priorizar intervenciones específicas sobre las variables clave identificadas. La combinación de las importancias obtenidas mediante RF como priors o distribuciones iniciales en las Redes Bayesianas mejora significativamente la capacidad explicativa y predictiva del modelo híbrido, maximizando las ventajas particulares de cada técnica.

4.4 Factibilidad de aplicación real en el sector público dominicano

La factibilidad de aplicar los modelos desarrollados en esta investigación dentro del sector público dominicano requiere considerar varios aspectos clave, incluyendo la disponibilidad de datos, la capacidad técnica y la estructura institucional existente.

Disponibilidad de datos

Actualmente, el sector público dominicano enfrenta limitaciones en términos de datos abiertos y confiables para realizar análisis predictivos robustos. Sin embargo, la metodología de generación de datos sintéticos utilizada en este estudio demuestra una alternativa efectiva que permite realizar simulaciones detalladas para prever riesgos y gestionar proyectos en ausencia de datos

reales suficientes. La implementación de un repositorio nacional de datos podría facilitar aún más la aplicación práctica y escalabilidad del modelo en diversas instituciones públicas.

Capacidad técnica

La aplicación práctica del modelo propuesto dependerá en gran medida de la capacidad técnica existente en las instituciones públicas dominicanas. El empleo de herramientas accesibles como Google Colab y PyCharm, combinado con la documentación detallada proporcionada por este estudio, permite superar parcialmente estas barreras. Sin embargo, será esencial promover programas de formación y capacitación continua en técnicas de aprendizaje automático y análisis probabilístico para garantizar una adopción efectiva y sostenida.

Infraestructura institucional

La estructura institucional vigente presenta ciertas rigideces inherentes a los procesos administrativos y regulatorios tradicionales. La adopción exitosa de modelos híbridos basados en aprendizaje automático y Redes Bayesianas podría encontrar desafíos en términos de resistencia al cambio, limitaciones presupuestarias, y marcos regulatorios poco adaptados a tecnologías avanzadas. Por tanto, es necesario un esfuerzo conjunto entre diversas entidades gubernamentales para ajustar normativas y procesos internos,

promoviendo un entorno más favorable y receptivo hacia innovaciones tecnológicas.

Ventajas potenciales

La implementación efectiva del modelo híbrido podría aportar múltiples beneficios prácticos al sector público dominicano:

- **Reducción de riesgos:** Mejora en la anticipación y gestión proactiva de riesgos asociados a proyectos tecnológicos.
- **Optimización de recursos:** Mayor eficiencia en el uso de recursos financieros y humanos mediante predicciones precisas y oportunas.
- **Transparencia y rendición de cuentas:** Fortalecimiento de la transparencia al disponer de métricas cuantitativas claras y explicables para la gestión de proyectos públicos.
- **Adaptabilidad:** Capacidad de respuesta mejorada ante condiciones cambiantes del entorno, especialmente relevantes en contextos VUCA (Volatilidad, Incertidumbre, Complejidad y Ambigüedad).

Recomendaciones para facilitar la implementación

Para aumentar la factibilidad y asegurar el éxito en la adopción práctica del modelo, se recomiendan las siguientes acciones específicas:

- Crear y mantener un repositorio público de datos de proyectos que permita la recopilación continua y actualización dinámica de información relevante.
- Promover programas específicos de capacitación técnica dirigidos a servidores públicos en metodologías ágiles, gestión de riesgos, y análisis predictivo basado en aprendizaje automático.
- Incentivar la colaboración interinstitucional y con centros académicos nacionales e internacionales para garantizar la transferencia continua de conocimiento y buenas prácticas.
- Establecer un marco normativo claro y flexible que facilite la incorporación y aplicación de tecnologías avanzadas en procesos de contratación y gestión pública.

Aunque existen desafíos significativos, la implementación práctica del modelo híbrido desarrollado es altamente factible, siempre que se aborden adecuadamente los factores técnicos, institucionales y normativos descritos, y se aprovechen efectivamente los beneficios potenciales identificados.

4.5 Conclusiones generales

Esta investigación ha demostrado que la integración de modelos híbridos de aprendizaje automático supervisado y redes bayesianas constituye una

herramienta efectiva y robusta para gestionar riesgos y complejidades en proyectos tecnológicos bajo metodologías ágiles en contextos VUCA, específicamente dentro del sector público dominicano.

Entre los hallazgos clave destacan:

1. **Importancia crítica de variables clave:** Las variables identificadas como más influyentes, tales como la complejidad del proyecto, el riesgo VUCA global, el presupuesto disponible, la adaptabilidad y la duración, son esenciales para evaluar y predecir el éxito de proyectos tecnológicos ágiles.
2. **Alto desempeño predictivo del modelo híbrido:** El modelo híbrido, **combinando** Random Forest y Naive Bayes, alcanzó una precisión del 91.76%, mostrando mejoras sustanciales sobre los modelos individuales que **solo utilizaron** redes bayesianas. Esto enfatiza la importancia de incorporar enfoques supervisados para optimizar la capacidad predictiva.
3. **Interpretabilidad y gestión efectiva de riesgos:** Aunque los modelos basados únicamente en Redes Bayesianas presentaron precisiones menores, su capacidad para ofrecer explicaciones causales y probabilísticas facilita significativamente la comprensión y gestión estratégica de riesgos en proyectos.

4. **Factibilidad técnica y operativa:** A pesar de ciertas limitaciones actuales, como la escasez de datos abiertos y las barreras institucionales y técnicas existentes, la adopción del modelo híbrido es plenamente viable. El uso de datos sintéticos, herramientas accesibles como Google Colab y PyCharm, y recomendaciones claras para formación técnica y adaptación normativa respaldan esta factibilidad.

Por tanto, la combinación estratégica de metodologías predictivas e interpretativas resulta altamente recomendable para mejorar la gestión de riesgos y toma de decisiones en proyectos tecnológicos ágiles. Además, fomentar un entorno institucional receptivo y técnicamente capacitado será fundamental para asegurar una implementación efectiva y sostenible en el sector público dominicano.

Recomendaciones

Guía práctica para líderes de proyecto: selección de metodología e integración BN + ML

Para los líderes de proyectos tecnológicos en entornos ágiles del sector público dominicano, se recomienda adoptar un enfoque híbrido basado en Redes Bayesianas (BN) y modelos de aprendizaje automático (ML) como Random Forest, debido a su capacidad para combinar precisión predictiva e

interpretabilidad causal. Específicamente, se sugiere:

- Identificar variables críticas: Utilizar resultados del modelo Random Forest para determinar las variables más influyentes en el éxito del proyecto.
- Calibrar distribuciones probabilísticas: Emplear estas importancias de variables como distribuciones iniciales (priors) en una Red Bayesiana, mejorando así la interpretación causal.
- Actualización dinámica: Incorporar métodos iterativos que actualicen regularmente el modelo conforme avance el proyecto, permitiendo ajustes oportunos a la gestión de riesgos y complejidad.
- Capacitación continua: Promover la formación en herramientas como Python, Colab, PyCharm, y en técnicas específicas como aprendizaje supervisado y análisis probabilístico para mantener al equipo actualizado y competente.

Propuesta de política pública: repositorio nacional de datos y capacitación en análisis probabilístico

Se recomienda la creación e implementación de un Repositorio Nacional de Datos Abiertos para Proyectos Tecnológicos. Este repositorio debe contener información detallada sobre variables clave de riesgo y complejidad en proyectos públicos, permitiendo una gestión basada en evidencia y facilitando la

evaluación continua de iniciativas tecnológicas.

- Estandarización y transparencia: Definir estándares claros y unificados para la recopilación, registro y publicación de datos.
- Privacidad y confidencialidad: Garantizar la anonimización efectiva de datos sensibles para proteger información crítica.
- Capacitación en análisis probabilístico: Implementar programas regulares de capacitación en metodologías estadísticas y probabilísticas (BN, ML), especialmente dirigidos a gestores de proyectos y analistas de datos del sector público.
- Fomento de alianzas estratégicas: Establecer colaboraciones entre instituciones académicas, gubernamentales y organismos internacionales para fortalecer la capacidad técnica y el intercambio de conocimiento.

Líneas futuras de investigación

Para avanzar en el conocimiento y práctica de la gestión ágil de riesgos en proyectos tecnológicos, se proponen las siguientes líneas de investigación:

- Aplicación en contextos reales: Validar y ajustar los modelos híbridos BN+ML desarrollados mediante estudios piloto en proyectos tecnológicos reales del sector público dominicano.

- Integración de datos dinámicos: Explorar la incorporación de datos en tiempo real provenientes de herramientas de gestión ágil (JIRA, Trello) para alimentar y ajustar continuamente las redes bayesianas.
- Expansión a modelos dinámicos avanzados: Desarrollar Redes Bayesianas Dinámicas (DBN) que permitan modelar la evolución temporal de los riesgos y la complejidad a través de iteraciones sucesivas en proyectos ágiles.
- Análisis de impacto organizacional: Evaluar el impacto cultural y organizacional de implementar modelos predictivos avanzados en la gestión pública, identificando factores clave para una adopción efectiva.

Estas recomendaciones contribuirán a mejorar significativamente la eficiencia, transparencia y efectividad de la gestión de proyectos tecnológicos en la República Dominicana, fortaleciendo así la capacidad institucional frente a los desafíos propios de los entornos VUCA.

Bibliografía

Ancveire, I. (2015). Software delivery risk management: Application of Bayesian networks in agile software development. *Information Technology and Management Science*, 18(1), 62–69. <https://doi.org/10.1515/itms-2015-0010>

Atlassian. (s. f.). Project Management Triangle Explained. Recuperado de <https://www.atlassian.com/agile/agile-at-scale/agile-iron-triangle>

Banco Interamericano de Desarrollo (BID). (2021, 7 de julio). Programa para mejorar la conectividad para la transformación digital en República Dominicana (DR-L1147). Recuperado de <https://www.iadb.org/es/proyecto/DR-L1147>

Barber, H. (1992). Incorporating VUCA into strategic leadership curricula. *Journal of Management Development*, 11(8), 5–12.

Beaulieu-Jones, B. K., Wu, Z. S., Williams, C., Lee, R., Bhavnani, S. P., Byrd, J. B., & Greene, C. S. (2019). Privacy-preserving generative deep neural networks support clinical data sharing. *Circulation: Cardiovascular Quality and Outcomes*, 12(7), e005122. <https://doi.org/10.1161/CIRCOUTCOMES.118.005122>

Bennett, N., & Lemoine, G. J. (2014). What VUCA really means for you. *Harvard Business Review*, 92(1–2), 27–42. <https://hbr.org/2014/01/what-vuca-really-means-for-you>

Bennis, W. G., & Nanus, B. (1985). *Leaders: The strategies for taking charge*. Harper & Row.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>

Catal, C., & Diri, B. (2009). A systematic review of software fault prediction studies. *Expert Systems with Applications*, 36(4), 7346–7354.
<https://doi.org/10.1016/j.eswa.2008.10.005>

Charalabidis, Y., Alexopoulos, C., & Loukis, E. (2016). A taxonomy of open government data research areas and topics. *Journal of Organizational Computing and Electronic Commerce*, 26(1–2), 41–63.
<https://doi.org/10.1080/10919392.2015.1124720>

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>

Chawla, N. V., et al. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
<https://doi.org/10.1613/jair.953>

Chawla, N. V., et al. (2002). SMOTE: Synthetic minority over-sampling technique.

Journal of Artificial Intelligence Research, 16, 321–357.

<https://doi.org/10.1613/jair.953>

Chickering, D. M. (2002). Optimal structure identification with greedy search. *Journal of Machine Learning Research*, 3, 507–554.

Clayton, D. G. (1978). A model for association in bivariate life-tables and its application in epidemiological studies of familial tendency in chronic disease incidence. *Biometrika*, 65(1), 141–151. <https://doi.org/10.1093/biomet/65.1.141>

Darwiche, A. (2009). *Modeling and Reasoning with Bayesian Networks* (2nd ed.). Cambridge University Press.

Diario Libre. (2024, 22 de marzo). Educación dice que logró recuperación de la matrícula escolar en 2023. Recuperado de <https://www.diariolibre.com/actualidad/educacion/2024/03/22/educacion-dice-que-logro-recuperacion-de-la-matricula-escolar-en-2023/2651409>

Duda, R. O., Hart, P. E., & Stork, D. G. (2001). *Pattern Classification* (2nd ed.). Wiley.

Entornos VUCA. (2019). ¿Qué son los entornos VUCA? Recuperado de <https://entornosvuca.com>

Grout, J., & Kluyver, T. (2020). *ipywidgets: Interactive HTML widgets for Jupyter notebooks*. Recuperado de <https://ipywidgets.readthedocs.io/>

Hagberg, A., Swart, P., & S Chult, D. (2008). Exploring network structure, dynamics, and function using NetworkX. In G. Varoquaux, T. Vaught, & J. Millman (Eds.), *Proceedings of the 7th Python in Science Conference* (pp. 11–15). Pasadena, CA. Recuperado de <https://networkx.org/>

Hammad, M., Inayat, I., & Zahid, M. (2019). Risk management in Agile software development: A survey. En *2019 International Conference on Frontiers of Information Technology (FIT)* (pp. 162–164). IEEE. <https://doi.org/10.1109/FIT.2019.00039>

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2^a ed.). Springer.

Heckerman, D. (1995). *A tutorial on learning with Bayesian networks*. Microsoft Research Technical Report.

Highsmith, J. (2009). *Agile project management: Creating innovative products* (2.^a ed.). Addison-Wesley.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>

Instituto Dominicano de las Telecomunicaciones (INDOTEL). (2025, 26 de mayo). Otorgamiento de concesiones y licencias vinculadas para la prestación de servicios públicos portadores y finales de telefonía y acceso a Internet

(INDOTEL-LPI-001-2023). Recuperado de
<https://indotel.gob.do/indotel-lpi-001-2023/>

Instituto Nacional de la Administración Pública (INAP). (2021, 16 de abril). Documento de referencia sobre innovación gubernamental de la República Dominicana. Recuperado de
<https://inap.gob.do/inap-presenta-documento-referencia-de-innovacion-gubernamental-de-la-republica-dominicana/>

Jordan, M. I. (2004). Graphical models. *Statistical Science*, 19(1), 140–155.
<https://doi.org/10.1214/088342304000000017>

Kitchenham, B. (2004). Procedures for performing systematic reviews (Keele University Technical Report TR/SE-0401).

Koller, D., & Friedman, N. (2009). Probabilistic graphical models: Principles and techniques. MIT Press.

Lauritzen, S. L., & Spiegelhalter, D. J. (1988). Local computations with probabilities on graphical structures and their application to expert systems. *Journal of the Royal Statistical Society: Series B*, 50(2), 157–224.

Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17), 1–5.

LibreTexts. (2022). Gestión de riesgos de proyectos: fundamentos y procesos.

Recuperado de <https://espanol.libretexts.org>

McKinney, W. (2012). Python for data analysis: Data wrangling with pandas, NumPy, and IPython. O'Reilly Media.

Mitchell, T. M. (1997). Machine learning. McGraw-Hill.

Murphy, K. P. (2012). Machine learning: A probabilistic perspective. MIT Press.

Nguyen, T. N., & Huynh, Q. T. (2020). Risk management in agile software project iteration scheduling using Bayesian networks. En *Frontiers in Artificial Intelligence and Applications* (Vol. 303, pp. 596–606). IOS Press.
<https://doi.org/10.3233/978-1-61499-900-3-596>

Oficina Gubernamental de Tecnologías de la Información y Comunicación (OGTIC) & Gabinete de Innovación y Desarrollo Digital. (2023, 4 de diciembre). República Dominicana da primeros pasos hacia el Pacto por la Innovación. Recuperado de <https://ogtic.gob.do/categoria/noticias/republica-dominicana-da-primeros-pasos-hacia-el-pacto-por-la-innovacion>

Oficina Gubernamental de Tecnologías de la Información y Comunicación (OGTIC) & Gabinete de Innovación y Desarrollo Digital. (2024, 2 de septiembre). OGTIC y el Gabinete de Innovación y Desarrollo Digital lanzan programa

“Semilleros Digitales Intro”. Recuperado de <https://presidencia.gob.do/noticias/ogtic-y-el-gabinete-de-innovacion-y-desarrollo-digital-lanzan-programa-semilleros-digitales-intro/>

Oliphant, T. E. (2006). A guide to NumPy. USA: Trelgol Publishing. Recuperado de <https://numpy.org/doc/>

Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. Foundations and Trends® in Information Retrieval, 2(1–2), 1–135. <https://doi.org/10.1561/15000000001>

Patki, N., Wedge, R., & Veeramachaneni, K. (2016). The synthetic data vault. En 2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA) (pp. 399–410). IEEE. <https://doi.org/10.1109/DSAA.2016.49>

Pearl, J. (1988). Probabilistic reasoning in intelligent systems: Networks of plausible inference. Morgan Kaufmann.

Pearl, J. (2000). Causality: Models, reasoning, and inference (2nd ed.). Cambridge University Press.

pgmpy Developers. (s. f.). pgmpy: A Python library for Probabilistic Graphical Models. Recuperado de <https://pgmpy.org/>

Phua, C., Lee, V., Smith, K., & Gayler, R. (2010). A comprehensive survey of data mining-based fraud detection research. arXiv:1009.6119.

Presidencia de la República Dominicana. (2024). Premio Nacional a la Innovación Pública, 4.ª edición. Recuperado de <https://presidencia.gob.do>

Presidencia de la República Dominicana. (2025, 19 de mayo). Presidente Abinader anuncia avances de la estrategia para convertir RD en un país más digital, inclusivo y seguro. Recuperado de <https://presidencia.gob.do/noticias/presidente-abinader-anuncia-avances-de-la-e-strategia-para-convertir-rd-en-un-pais-mas-digital-inclusivo-y-seguro>

Project Management Institute – Capítulo Madrid. (2022). Gestión de riesgos en proyectos de alta complejidad. Recuperado de <https://pmi-mad.org>

Project Management Institute. (2017). A guide to the project management body of knowledge (PMBOK® Guide) (6.ª ed.). PMI.

Project Management Institute. (s. f.). Definition of project risk and risk management. Recuperado de <https://www.pmi.org/learning/library/risk-management-9096>

Qusef, A. (2015). Risk management in Agile software development: A comparative study. En Proceedings of the 36th International Conference on Software Engineering (ICSE) (pp. 24–35). IEEE.

Robert, C. P., & Casella, G. (2004). Monte Carlo statistical methods (2nd ed.). Springer.

Rubinstein, R. Y., & Kroese, D. P. (2016). Simulation and the Monte Carlo Method (3^a ed.). Wiley.

Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3), 1–22. <https://doi.org/10.18637/jss.v035.i03>

Serrador, P., & Pinto, J. K. (2015). Does Agile work?—a quantitative analysis of agile method versus waterfall. *International Journal of Project Management*, 33(5), 1040–1051. <https://doi.org/10.1016/j.ijproman.2015.01.006>

Spirtes, P., Glymour, C., & Scheines, R. (2000). Causation, Prediction, and Search (2nd ed.). MIT Press.

Taddy, M. (2015). Distributed multinomial regression. *The Annals of Applied Statistics*, 9(1), 204–235. <https://doi.org/10.1214/14-AOAS782>

The Standish Group. (2020). CHAOS report 2020. Recuperado de https://www.standishgroup.com/sample_research_files/CHAOSReport2020.pdf

van Rossum, G., & Drake, F. L. (2009). Python 3 Reference Manual. Scotts Valley, CA: CreateSpace. Recuperado de <https://docs.python.org/3/>

Wainwright, M. J., & Jordan, M. I. (2008). Graphical models, exponential families, and variational inference. *Foundations and Trends® in Machine Learning*, 1(1–2), 1–305. <https://doi.org/10.1561/22000000001>

Wirtz, B. W., Weyerer, J. C., & Becker, M. (2022). Open government data: A systematic literature review of empirical research. *Electronic Markets*, 32, 2381–2408. <https://doi.org/10.1007/s12525-022-00582-8>

Zhang, H. (2004). The optimality of Naïve Bayes. *AAAI/IAAI*, 3, 562–567.

Zhang, N. L. (2012). *Bayesian Networks: From Construction to Inference*. Springer.

Zhang, Z., Rao, G., Cao, J., & Zhang, L. (2014). Software process risk measurement model based on Bayesian network. En *Proceedings of the IEEE International Conference on Software Engineering Service Science (ICSESS)* (pp. 41–44). <https://doi.org/10.1109/ICSESS.2014.6933510>

Anexos

A. Diagramas de Redes Bayesianas

Figura 2: Red Bayesiana HillClimbSearch + BicScore

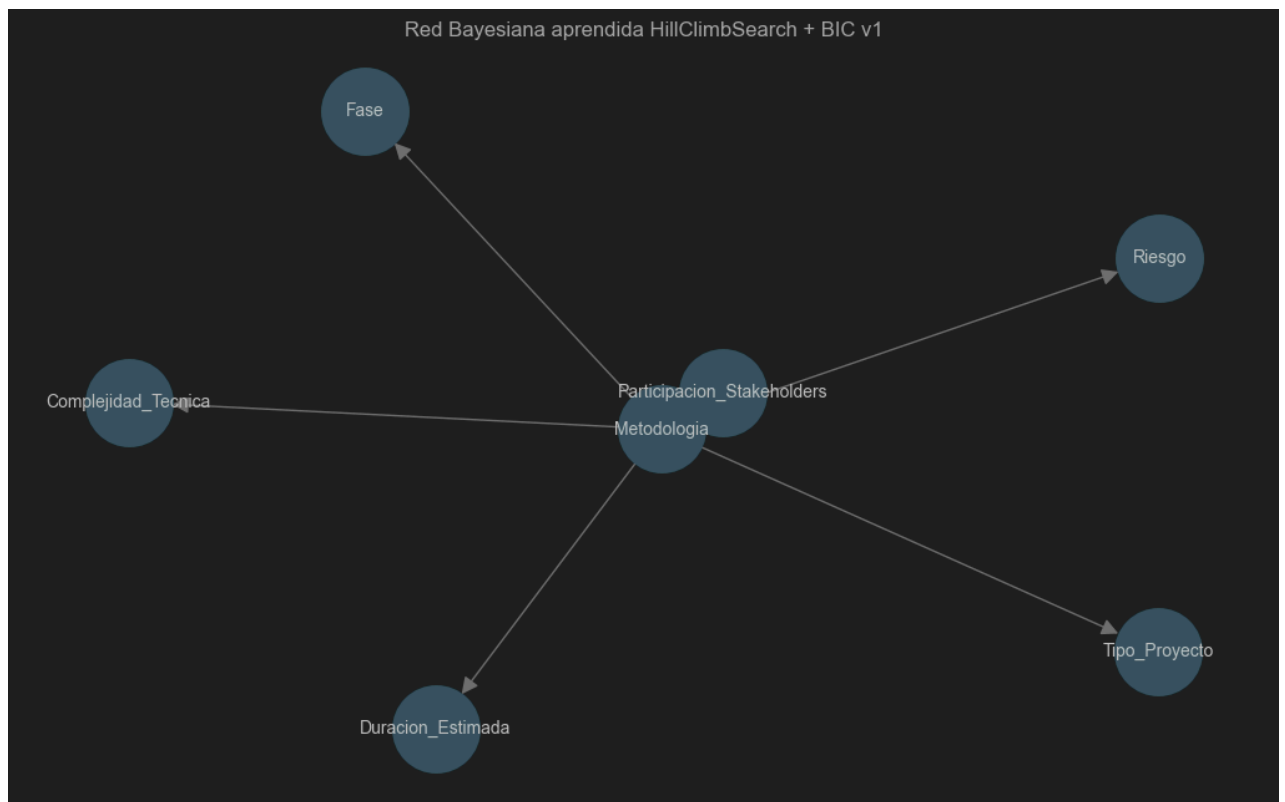


Figura 3: Red Bayesiana HillClimbSearch + K2Score



Figura 4: Red Bayesiana con el algoritmo Peter-Clark


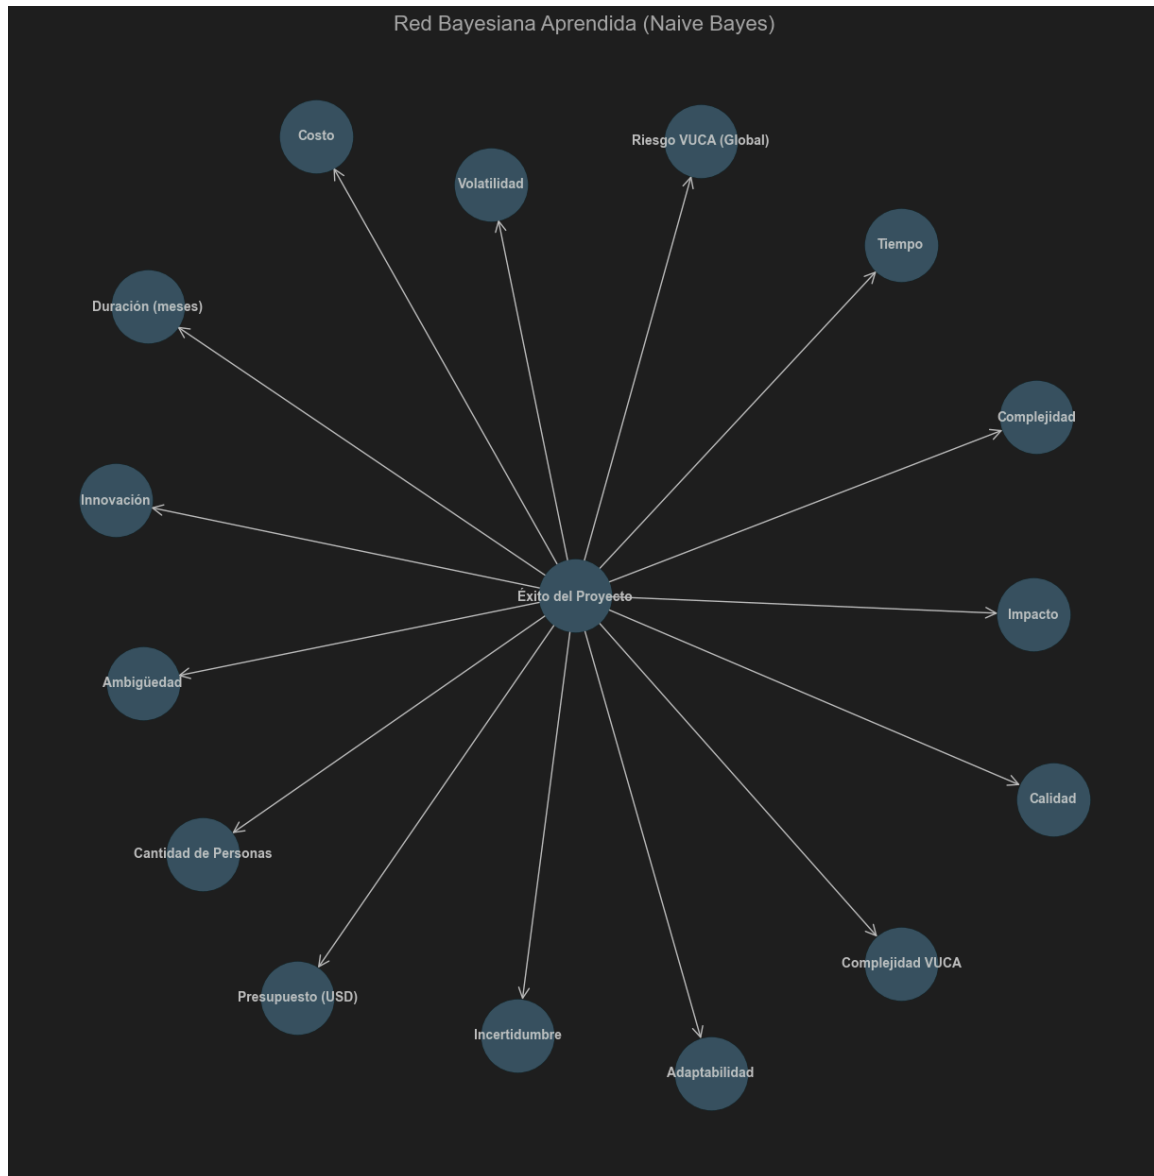


Figura 5: Red Bayesiana Random Forest + Naives Bayes



B. Código Colab / PyCharm

El código completo se incluye en dos notebooks de Jupyter (.ipynb):

1. **v1_Modelo_Uno_Naives_Bayes.ipynb**
2. **v1_Modelo_Dos_Random_Forest_Naives_Bayes.ipynb**

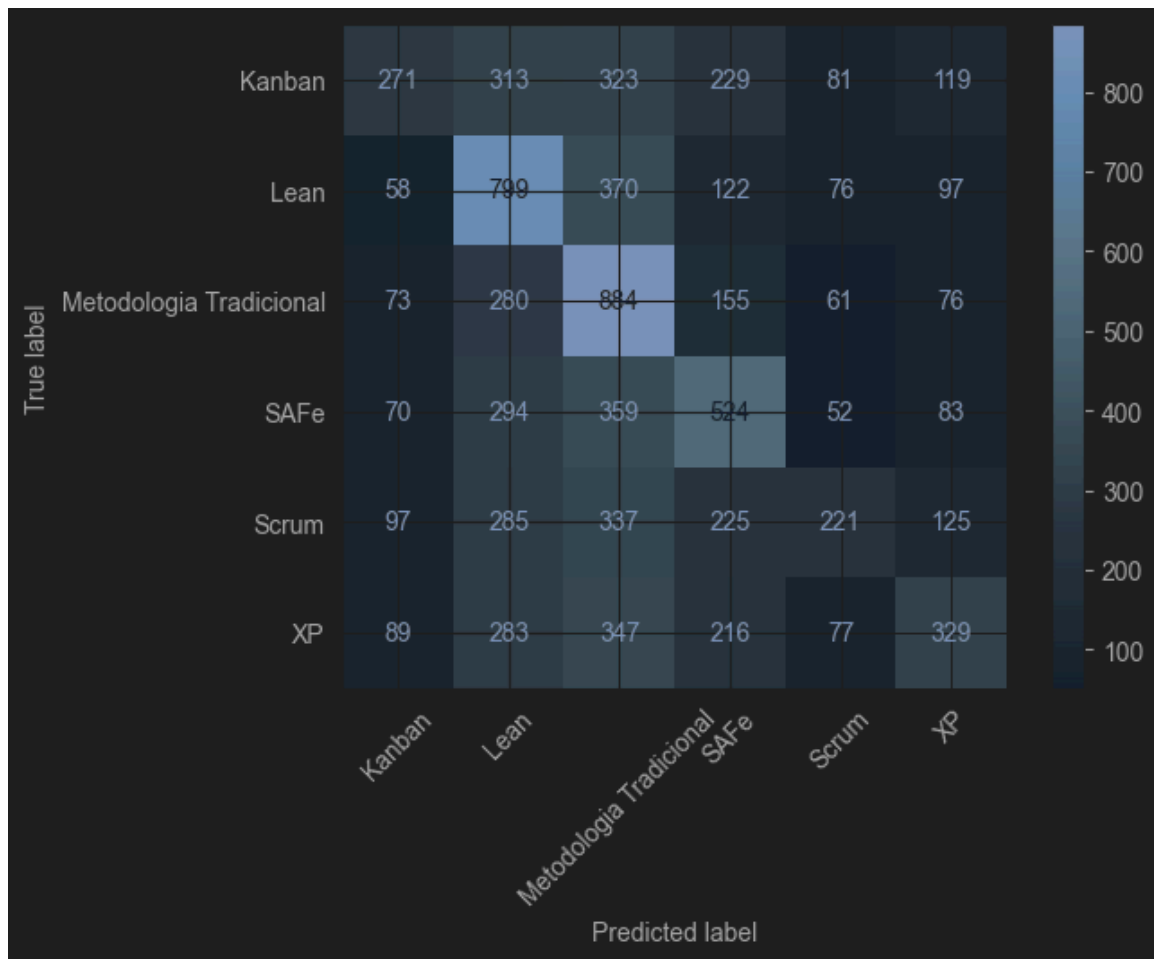
Ambos archivos estarán incluidos en el paquete ZIP que acompaña este TFM, de modo que puedan abrirse y ejecutarse tanto en Google Colab como en PyCharm (con el plugin de Jupyter).

- Estos notebooks contienen todos los bloques de código comentados y organizados según la estructura del documento.
- Para usar en PyCharm, es suficiente con instalar el soporte de Jupyter y las dependencias indicadas en la sección 3.6.1.

C. Métricas y visualizaciones (ROC, Confusion Matrix)


Precisión en prueba HillClimbSearch + BIC v1: 36.05%

Matriz de confusión (datos de prueba):




Precisión en prueba K2Score v1: 36.05%

Matriz de confusión (datos de prueba):




Precisión en prueba del modelo PC: 32.04%

Matriz de confusión (datos de prueba) para el modelo PC:




D. Reporte de importancias de Random Forest

Precisión del Modelo Predictivo: 94.05%



E. Reporte de importancias de Random Forest + Naives Bayes

Precisión Red Bayesiana: 91.76%



F. Ficha técnica de hardware y consumo de recursos

Observación: Estos valores reflejan el estado al momento de la ejecución. Para una referencia precisa, conviene mediciones in situ (por ejemplo con `htop`, `nvidia-smi` o el Monitor de recursos de Windows).

Tipo	Valor
Sistema Operativo	Windows 10
CPU	AMD Ryzen 9 7900X 12-Core Processor @ 4 700 MHz
Cores (físicos)	12
Cores (lógicos / hilos)	24
Frecuencia Base	4 700 MHz
RAM Total	32 GB
Frecuencia RAM	6 000 MHz

Uso Actual de RAM	~35 % (≈10.9 GB usados)
GPU 0	NVIDIA GeForce RTX 3080 (10 GB VRAM)
GPU 1	AMD Radeon (TM) Graphics (memoria no especificada)
Almacenamiento Total	954 GB
Almacenamiento Usado	101 GB
Almacenamiento Libre	853 GB
Uso del Disco (C:)	~4 %